

Dokumentacja techniczna projektu

**Dokumentacja projektu grupowego
ID-346 - Analiza bio-sygnałów do identyfikacji osób**

Mikołaj Kuźmich 198291, Jakub Dąbrowski 197629, Mikołaj Jaworski 197636

1 Konwencje

1.1 Metoda pomiarowa

Dla kamizelki BRV wyznaczono następujący sposób dostosowania poziomu pasów:

- pas 1 - pod pachami
- pas 2 - na linii sutków
- pas 3 - na poziomie najniższego z żeber
- pas 4 - na poziome pępka
- pas 5 - na poziomie pasa

Wymaga się, by badany na potrzeby badania siedzącego, zajmującego około 15 minut nie wykonywał następujących czynności:

1.2 Struktura bazy danych

W celu usprawnionego przechowywania informacji zebranych w trakcie realizacji projektu grupowego utworzono bazę danych MongoDB. Baza danych zawiera podstawowo 2 kolekcje:

- segmenty badań składające się z pomiarów - **segments**

Pole	Typ	Opis
sourceMeasurementDate	timestamp	data wykonania pomiaru źródłowego
measurementLength	int	długość pomiaru w minutach
subject	string	PESEL osoby badanej
sampleArray	Sample[]	tablica próbek stanowiących jeden segment pomiaru

- wyekstrahowane cechy z tych segmentów - **features**

2 Dane

2.1 Obiekt pomiaru

2.2 Etapy przetwarzania danych

2.2.1 Oddzielanie oddechów

Celem tego etapu jest wstępne podzielenie sygnału na mniejsze części reprezentujące kolejne oddechy w analizowanym pomiarze. Realizowane jest to poprzez wyznaczenie wszystkich maksymów i minimów lokalnych oraz zapisanie ich w programie tak, by przygotować je do dalszej obróbki.

- **Dane wejściowe:**
Zbiór wartości odstawiania od średniej wartości sygnału na danym pasie, dla każdego pasa w kamizelce pomiarowej. Każda z tych wartości przypisany ma odpowiedni znacznik czasu od rozpoczęcia pomiaru, w którym pobrano próbkę.
- **Dane wyjściowe:**
Zbiór punktów reprezentujących wszystkie maksyma i minima lokalne sygnału wraz z przypisanymi im wartościami znaczników czasu.

2.2.2 Ekstrakcja cech

Po podzieleniu danych na segmenty, a więc ostatecznym przygotowaniu ich do analizy, należy rozpocząć proces pozyskiwania informacji potrzebnych do prawidłowego działania klasyfikatora. Sama sieć neuronowa nie potrzebuje zdefiniowanych cech sygnału, by funkcjonować, jednak w celach badawczych, zdecydowano się na ich ekstrakcję ze względu na możliwość sprawdzenia różnic we wzorcach oddechowych objętych analizą osób.

- **Dane wejściowe:**
Zbiór plików zawierających podzielone na segmenty dane z pomiarów po wszystkich przekształceniach, w których nazwa wyznacza etykietę, ponieważ zawiera typ aktywności oraz identyfikator osoby
- **Dane wyjściowe:**
Plik wyjściowy `extracted_features.jsonl` w formacie `.jsonl`, zawierający wektory cech wyznaczone dla kolejnych segmentów danych pomiarowych.

Cechy składające się na wektor dla segmentu:

- `bpm` - liczba oddechów na minutę
- `breath_depth` - wyznaczone poprzez uśrednienie wartości szczytów oddechów w całym segmencie dla środkowego pasa
- `breath_depth_std` - odchylenie standardowe sygnału, jako głębokość oddechu dla środkowego pasa
- `belt_share` - udział poszczególnych pasów w oddychaniu, reprezentowany przez 5 wartości, po jednej dla każdego pasa. Jest on wyznaczany poprzez zsumowanie wartości głębokości oddechu dla każdego pasa, tworzy to mianownik ułamka, który liczony jest osobno dla każdego tensometru, gdzie licznikiem jest głębokość oddechu dla tego konkretnego sensora


- **belt_share_std** - wyznaczany jest on analogicznie do powyższego, korzysta jednak z wyżej wspomnianych odchyłeń standardowych sygnału, jako głębokości
- **breathing_phase_lengths** - jest to wartość średnia czasu trwania kolejnych faz oddychania, a mianowicie: faza wdechu, pauza po wdechu, faza wydechu, pauza po wydechu

2.3 Wizualizacja danych


Aby zweryfikować poprawność całego procesu przetwarzania należało w odpowiedni sposób zwizualizować dane pozyskane w ramach projektu. Jest to niezbędny etap, gdyż pozwala na ewaluację postępów.

Trzy główne cele etapu to:

1. **Weryfikacja rozróżnialności osób po przetwarzaniu** - Aby móc zweryfikować poprawność procesu przetwarzania, trzeba zwizualizować zebrane dane. Jest to realizowane za pomocą algorytmów redukujących liczbę cech: **MDS** oraz **PCA**. W tym podpunkcie liczba składowych, w celach poglądowych, obniżana jest do dwóch. Dzięki tym wartościom jesteśmy w stanie wyznaczyć kierunek, będący transformacją macierzy danych, który spowoduje największe możliwe zróżnicowanie zbioru danych. Zakładając więc, że różnice we wzorcach oddechowych między różnymi osobami będą stosunkowo dużo większe niż między różnymi momentami dla tej samej osoby, jesteśmy w stanie uzyskać odpowiednią, wizualną separację danych, zgodną z etykietami.
2. **Wyznaczenie najbardziej istotnych cech dla klasyfikatora** - W celu wyżej wspomnianej weryfikacji przetwarzania danych, należało zredukować liczbę wymiarów wektora cech, tak by ten mógł zostać przedstawiony w sposób możliwy do analizy przez człowieka. Zostały więc wyznaczone w ten sposób najbardziej istotne elementy sygnału. Dzięki temu jesteśmy w stanie zredukować ostateczną ich liczbę, co pozytywnie wpływa na ryzyko zbytniego dopasowania oraz pozwala na mniejszy nakład obliczeniowy związany np. ze skorelowanymi zmiennymi.



Rysunek 2.1: Cechy po wywołaniu algorytmu MDS przedstawione na dwuwymiarowym wykresie.




Rysunek 2.2: Cechy po wywołaniu algorytmu PCA przedstawione na dwuwymiarowym wykresie.

3. **Kontrola jakości przez prosty klasyfikator** - Ostatnim celem Wizualizacji jest kontrola jakości rozwiązania dzięki klasyfikatorowi. Skorzystano więc z prostego klasyfikatora binarnego: **SVM**, który wykorzystywany jest do porównania zbiorów danych o dwóch różnych etykietach. Przy okazji wizualizacji wyznaczana jest też wartość liczbową dokładności takiego klasyfikatora. Użycie tego konkretnego algorytmu pozwoli na podkreślenie ewentualnych problematycznych par podobnych zbiorów danych. Dodatkowo, dokonywana jest również ewaluacja za pomocą sieci **LSTM**.


Opis przeprowadzonej ewaluacji

2.3.1 SVM - Support Vector Machine


Za pomocą klasyfikatora SVM, jesteśmy w stanie podzielić zbiór na dwa, poprzez znalezienie odpowiedniej hiperpłaszczyzny maksymalizującej margines między dwoma klasami. W związku z tym, że jest on klasyfikatorem binarnym, należało wywołać go osobno dla każdej możliwej pary etykiet w ogólnym zbiorze zredukowanych cech. W ten sposób uzyskujemy podział dla wszystkich kombinacji oraz związaną z nimi dokładność. Poniżej przykłady dla zbioru danych 3 osób.



Zmierzona dokładność: Accuracy for JD_sit and MJ_sit: 95.56%



Zmierzona dokładność: Accuracy for JD_sit and MK_sit: 84.93%



Zmierzona dokładność: Accuracy for MJ_sit and MK_sit: 91.07%

2.3.2 LSTM - Long Short-Term Memory

not yet

3 Kod źródłowy

W tym rozdziale wyróżniono funkcje odpowiedzialne za przetwarzanie danych, używając transformacji opisanych w rozdziale Dane.