

Dokumentacja techniczna projektu

**Dokumentacja projektu grupowego
ID-346 - Analiza bio-sygnałów do identyfikacji osób**

Mikołaj Kuźmich 198291, Jakub Dąbrowski 197629, Mikołaj Jaworski 197636

Spis treści

1	Konwencje	4
1.1	Słownik pojęć:	4
1.2	Metoda pomiarowa	5
1.3	Wykorzystane technologie	5
2	Dane	7
2.1	Obiekt pomiaru	7
2.1.1	Charakterystyka surowych danych	7
2.2	Etapy przetwarzania danych	8
2.2.1	Obsługa danych wejściowych i wstępne przetwarzanie	8
2.2.2	Oddzielanie oddechów	9
2.2.3	Wykrywanie anomalii	9
2.2.4	Podział danych na segmenty i resampling	11
2.2.5	Ekstrakcja cech	12
2.3	Wizualizacja danych	13
2.3.1	SVM - Support Vector Machine	14
2.4	Tworzenie profili oddechowych osób	16
2.4.1	Metodyka wyznaczania profilu	16
2.4.2	Zastosowanie profili	18
3	Kod źródłowy	19
3.1	Przepływ sterowania w projekcie	19
3.2	Architektura systemu	19
3.3	Kluczowe funkcje i przepływ danych wewnątrz skryptu <code>main</code>	19
3.4	Kluczowe funkcje i przepływ danych wewnątrz skryptu <code>extract_features</code>	20
3.5	Kluczowe funkcje i przepływ danych wewnątrz skryptu <code>visualize_data</code>	20
3.6	Kluczowe funkcje i przepływ danych wewnątrz skryptu <code>create_data_profiles</code>	20
3.7	Utworzenie połączenia oraz obsługa zapytań do API - DatabaseHandler	21
3.8	Interakcja z archiwami pomiarów	21
4	Serwer BRICS	22
4.1	BRICS DB	22
4.2	API	23
4.2.1	Punkty końcowe API	23
4.2.2	Szczegółowa realizacja punktów końcowych	23
4.2.3	Redis	24
4.2.4	Celery Worker	24
4.2.5	Celery Beat	25
4.3	Zabezpieczenia	25
4.3.1	Konsola zdalna	26
4.3.2	API	26
4.3.3	Docker	26
5	Płytką pośrednicząca w komunikacji	27
5.1	Architektura płytki	27
5.2	Wielowątkowa aplikacja pośrednicząca	27
5.3	Serwer Bluetooth	28
5.3.1	Działanie serwera Bluetooth LE	28

5.4	Sygnalizowanie stanu płytki GPIO	28
5.5	Przykładowy scenariusz użycia	28
6	Model BRICS	29
6.1	Organizacja repozytorium	29
6.2	Klasyfikatory	30
6.3	Dane	30
6.4	Model	30
6.4.1	Klasy będące pojemnikami na dane	30
6.4.2	Model nauczania maszynowego	31
6.4.3	Założenia treningowe	31
6.4.4	Przebieg treningu	33
6.5	Aplikacja	35

1 Konwencje


1.1 Słownik pojęć:

- **BRV (Breathing Rhythm Vest)** - kamizelka pomiarowa wyposażona w tensometry, akcelerometry i żyroskopy, służąca do pomiaru rytmu oddechowego u człowieka. Główny instrument pomiarowy, wykonany w ramach pracy magisterskiej innej grupy studentów WETI
- **ADC (Analog-to-Digital Converter)** - przetwornik analogowo-cyfrowy, urządzenie elektroniczne służące do konwersji sygnałów analogowych na cyfrowe. Tu jest to część kamizelki BRV, która przetwarza sygnały z tensometrów na dane cyfrowe do dalszej analizy.
- **Pomiar/badanie** - całość pliku z danymi zebranymi podczas jednego badania, trwającego określonej ilości czasu (np. 10 minut).
- **Próbka** - pojedynczy znacznik czasu z przypisanymi wartościami sygnału ADC z czujników kamizelki BRV.
- **Segment** - wyodrębniony fragment pomiaru o określonej długości czasowej (np. 2 minuty), wykorzystywany do analizy i ekstrakcji cech. Zawiera wiele próbek.
- **Cecha** - wyodrębniona wartość liczbowa lub wektor wartości liczbowych, będąca numeryczną reprezentacją pewnego aspektu sygnału oddechowego w danym segmencie.

1.2 Metoda pomiarowa

Dla kamizelki BRV wyznaczono następujący sposób dostosowania poziomu pasów:

- pas 1 - pod pachami
- pas 2 - na linii sutków
- pas 3 - na poziomie najniższego z żeber
- pas 4 - na poziomie pępka
- pas 5 - na poziomie pasa



Rysunek 1.1: Graficzna reprezentacja sposobu noszenia kamizelki pomiarowej BRV.

Obecnie wszystkie wykonane pomiary odbywały się w pozycji siedzącej i w stanie spoczynku. Dopuszczalne były jedynie niewielkie ruchy ciała, takie jak poprawienie pozycji siedzącej czy zmiana ułożenia rąk. Dodatkowo dopuszczaliśmy następujące czynności:

- picie wody,
- używanie telefonu komórkowego
- czytanie książki
- korzystanie z komputera - tu należy zaznaczyć, że było to korzystanie bez znaczących ruchów ciała i w sposób niewzbudzający silnych emocji (może to powodować zmiany naturalnego rytmu oddechowego).

Całe badanie zazwyczaj trwało około 15 minut, ale wykonaliśmy też kilka dłuższych pomiarów. Najdłuższy wykonany pomiar trwał 60 minut. Całkowicie udało się zebrać około 5 godzin materiału pomiarowego od 3 różnych osób. Powiększenie tego zbioru (zarówno pod względem czasu pomiarowego, jak i liczby osób) jest priorytetem na przyszłość.

1.3 Wykorzystane technologie

W projekcie zostały wykorzystane następujące technologie:

- Język programowania Python w wersji 3.12
- Oprogramowanie LaTeX do tworzenia dokumentacji technicznej

- Biblioteka NumPy do obliczeń numerycznych
- Biblioteka SciPy do analizy sygnałów
- Biblioteka Matplotlib do wizualizacji danych
- Biblioteka Seaborn do wizualizacji danych
- Biblioteka SciKit-learn do uczenia maszynowego
- Biblioteka Pathlib do operacji na ścieżkach plików
- Baza danych MongoDB do przechowywania danych pomiarowych
- Framework FastAPI do stworzenia REST API dla bazy danych
- Serwer WWW Uvicorn
- Zbiór narzędzi do wytwarzania i uruchamiania aplikacji skonteneryzowanych Docker

2 Dane

2.1 Obiekt pomiaru

Obiektem pomiaru jest sygnał oddechowy rejestrowany przez system kamizelki sensorycznej. Pomiar opiera się na analizie zmian obwodu klatki piersiowej i brzucha użytkownika podczas cyklu oddechowego.

System wykorzystuje dwa główne typy sensorów:

- **Tensometry (ADC):** Pięć pasów tensometrycznych rozmieszczonych na różnych wysokościach tułowia. Rejestrują one siłę naciągu pasów, która zmienia się wraz z nabieraniem i wypuszczaniem powietrza.
- **Jednostki inercyjne (IMU):** Zestaw akcelerometrów i żyroskopów monitorujących orientację przestrzenną oraz ruchy klatki piersiowej. Na chwilę obecną dane z tych sensorów nie są wykorzystywane.

2.1.1 Charakterystyka surowych danych

Dane przesyłane z urządzenia mają formę strumienia obiektów JSON. Każda próbka zawiera timestamp oraz surowe odczyty binarne z sensorów.

Poniżej przedstawiono strukturę kluczowych pól surowej próbki:

Klucz sygnału	Typ	Opis fizyczny
hrs, min, sec, ms	czas	Czas rejestracji próbki od uruchomienia urządzenia.
adc1...adc5	24-bit	Trzy 8-bitowe rejestry (np. 23_to_16) tworzące naciąg pasa zapisany w formacie U2
imu1...imu5_acc	m/s ²	Składowe przyspieszenia liniowego w osiach X, Y, Z dla 5 punktów kamizelki.
imu1...imu5_gyr	deg/s	Prędkość kątowna (orientacja) klatki piersiowej i pleców.
output_status	bool	Flaga diagnostyczna określająca poprawność pracy danego sensora.

Tabela 2.1: Opis składowych danych surowych.

Poniżej przedstawiono przykładowy format surowej próbki:

```
"hrs": 0, "min": 0, "sec": 13, "ms": 457,  
"adc1_output_23_to_16": 240, "adc1_output_15_to_8": 8,  
"adc1_output_7_to_0": 165, "adc2_output_23_to_16": 255,  
"adc2_output_15_to_8": 36, "adc2_output_7_to_0": 15,  
"adc3_output_23_to_16": 243, "adc3_output_15_to_8": 99,  
"adc3_output_7_to_0": 199, "adc4_output_23_to_16": 253,  
"adc4_output_15_to_8": 161, "adc4_output_7_to_0": 55,  
"adc5_output_23_to_16": 238, "adc5_output_15_to_8": 46,  
"adc5_output_7_to_0": 1, "imu1_output_acc_x": 2384,  
"imu1_output_acc_y": 237, "imu1_output_acc_z": 16526,  
"imu1_output_gyr_x": -12, "imu1_output_gyr_y": -11,
```

```

"imu1_output_gyr_z": 17, "imu2_output_acc_x": 3021,
"imu2_output_acc_y": 888, "imu2_output_acc_z": 16327,
"imu2_output_gyr_x": -1, "imu2_output_gyr_y": -31,
"imu2_output_gyr_z": 17, "imu3front_output_acc_x": 5654,
"imu3front_output_acc_y": 866, "imu3front_output_acc_z": 15351,
"imu3front_output_gyr_x": -2, "imu3front_output_gyr_y": 7,
"imu3front_output_gyr_z": -5, "imu3back_output_acc_x": -831,
"imu3back_output_acc_y": -2094, "imu3back_output_acc_z": 16238,
"imu3back_output_gyr_x": 2, "imu3back_output_gyr_y": 9,
"imu3back_output_gyr_z": -9, "imu4_output_acc_x": 1997,
"imu4_output_acc_y": 655, "imu4_output_acc_z": 15972,
"imu4_output_gyr_x": -5, "imu4_output_gyr_y": -4,
"imu4_output_gyr_z": -2, "imu5_output_acc_x": -768,
"imu5_output_acc_y": 437, "imu5_output_acc_z": 16111,
"imu5_output_gyr_x": -3, "imu5_output_gyr_y": 3,
"imu5_output_gyr_z": 7, "output_status_adc1": true,
"output_status_adc2": true, "output_status_adc3": true,
"output_status_adc4": true, "output_status_adc5": true,
"output_status_imu1": true, "output_status_imu2": true,
"output_status_imu3front": true, "output_status_imu3back": true,
"output_status_imu4": true, "output_status_imu5": true,
"output_status_padding": 0

```

2.2 Etapy przetwarzania danych

2.2.1 Obsługa danych wejściowych i wstępne przetwarzanie

Pierwszym etapem przetwarzania danych jest ich wczytanie oraz odpowiednie sformatowanie. Dane, zgodnie z opisem w punkcie 2.1, są przechowywane w plikach `.jsonl`. Każda linia reprezentuje pojedynczą próbkę zarejestrowaną przez kamizelkę pomiarową.

Wczytywanie odbywa się sekwencyjnie. Każda linia zawiera surowe dane czasowe (godziny, minuty, sekundy, milisekundy), 24-bitowe wartości z pięciu przetworników ADC (podzielone na trzy 8-bitowe składowe) oraz dane z czujników inercyjnych IMU.

W celu ułatwienia dalszej obróbki, każda z tych linii jest parsowana do wewnętrznej struktury danych. Proces ten obejmuje połączenie trzech 8-bitowych rejestrów każdego z pięciu kanałów ADC w jedną wartość liczbową, która następnie jest przeliczana na napięcie (wolt) zgodnie ze specyfikacją zastosowanych tensometrów.

Struktura danych wynikowych

Po wstępnym przetworzeniu dane są normalizowane i zapisywane w formie uproszczonych obiektów JSON, które stanowią podstawową jednostkę danych w dalszych etapach projektu. Przykładowy format przetworzonego segmentu (np. 2-minutowego) wygląda następująco:

```

{
  "timestamp": 0,
  "adc_outputs": [
    0.0002464437,
    0.0003881085,
    0.0004560553,
    -1.75746999e-05,
    0.0002706136
  ]
}

```


Tu warto dodać, że dla większości obliczeń wykonywanych w dalszych etapach takich jako wyciąganie cech, separacja oddechów czy wykrywanie anomalii pracujemy na sygnale dla środkowego ADC, eksperymentalnie ustaliliśmy, że jest on najbardziej miarodajny w kontekście analizy oddechu, a praca z jednym czujnikiem znacznie upraszcza cały proces.

2.2.2 Oddzielanie oddechów

Celem tego etapu jest wstępne podzielenie sygnału na mniejsze części reprezentujące kolejne oddechy w analizowanym pomiarze. Realizowane jest to poprzez wyznaczenie wszystkich maksymów i minimów lokalnych oraz zapisanie ich w programie tak, by przygotować je do dalszej obróbki.

- **Dane wejściowe:**

Zbiór wartości odstawiania od średniej wartości sygnału na danym pasie, dla każdego pasa w kamizelce pomiarowej. Każda z tych wartości przypisany ma odpowiedni znacznik czasu od rozpoczęcia pomiaru, w którym pobrano próbkę.

- **Dane wyjściowe:**

Zbiór punktów reprezentujących wszystkie maksyma i minima lokalne sygnału wraz z przypisanymi im wartościami znaczników czasu.

2.2.3 Wykrywanie anomalii

Kolejnym kluczowym etapem jest identyfikacja oraz eliminacja anomalii (ang. *outlier detection*). Sygnał z czujników tensometrycznych w kamizelce jest podatny na zakłócenia wynikające z nagłych ruchów użytkownika, poprawiania kamizelki czy chwilowych błędów transmisji danych. W ten sposób mogą pojawić się oddechy o nietypowych wartościach, które mogą negatywnie wpłynąć na jakość analizy i klasyfikacji.

Proces ich wykrywania i usuwania opiera się na analizie statystycznej zbioru wyznaczonych wcześniej ekstremów (maksimów i minimów) oraz odległości czasowych między nimi.

- **Kryteria wykrywania anomalii:**


- **Amplituda:** Odrzucane są oddechy o wartościach należących do górnych i dolnych kwartyli rozkładu amplitud. Obecnie odrzucamy około jeden procent oddechów z każdej strony rozkładu.
- **Częstotliwość:** Odrzucane są oddechy o zbyt krótkich oraz długich odległościach między wykrytymi wcześniej maksymami. Obecnie odrzucamy około jeden procent oddechów z każdej strony rozkładu.

- **Dane wejściowe:**


Zbiór par (znacznik czasu, wartość) dla zidentyfikowanych maksimów i minimów lokalnych z poprzedniego etapu oraz znormalizowany sygnał oddechowy.

- **Dane wyjściowe:**


Przefiltrowany zbiór punktów (zmodyfikowany sygnał oddechowy), o odpowiednio przesuniętych wartościach znaczników czasu.




Rysunek 2.1: Wykryte anomalie na podstawie amplitudy dla przykładowego sygnału.



Rysunek 2.2: Wykryte anomalie na podstawie Częstotliwości dla przykładowego sygnału.



Rysunek 2.3: Wykryte anomalie po usunięciu artefaktów dla przykładowego sygnału.



Rysunek 2.4: Odtworzony sygnał po usunięciu anomalii dla przykładowego sygnału.

2.2.4 Podział danych na segmenty i resampling

Ostatnim krokiem przygotowania danych przed ekstrakcją cech jest podział przefiltrowanego sygnału na okna czasowe (segmenty) o stałej długości dwóch minut oraz wykonanie resamplingu.

Najpierw sygnał jest resamplowany do za pomocą interpolacji liniowej (funkcja `interp1d` z biblioteki SciPy) do Częstotliwości 10 Hz, a następnie dzielony na segmenty. Dzięki temu każdy segment zawiera około 1200 próbek. Sam algorytm podziału na segmenty jest raczej prosty - rozpoczynamy od początku sygnału i zapisujemy do odpowiednio nazwanych plików `.json1` kolejne próbki danych o długości dwóch minut.

2.2.5 Ekstrakcja cech

Po podzieleniu danych na segmenty, a więc ostatecznym przygotowaniu ich do analizy, należy rozpocząć proces pozyskiwania informacji potrzebnych do prawidłowego działania klasyfikatora. Sama sieć neuronowa nie potrzebuje zdefiniowanych cech sygnału, by funkcjonować, jednak w celach badawczych, zdecydowano się na ich ekstrakcję ze względu na możliwość sprawdzenia różnic we wzorcach oddechowych objętych analizą osób.

- **Dane wejściowe:**

Zbiór plików zawierających podzielone na segmenty dane z pomiarów po wszystkich przekształceniach, w których nazwa wyznacza etykietę, ponieważ zawiera typ aktywności oraz identyfikator osoby

- **Dane wyjściowe:**

Plik wyjściowy `extracted_features.jsonl` w formacie `.jsonl`, zawierający wektory cech wyznaczone dla kolejnych segmentów danych pomiarowych.

Cechy składające się na wektor dla segmentu:

- **bpm** - liczba oddechów na minutę
- **breath_depth** - wyznaczone poprzez uśrednienie wartości szczytów oddechów w całym segmencie dla środkowego pasa
- **breath_depth_std** - odchylenie standardowe sygnału, jako głębokość oddechu dla środkowego pasa
- **belt_share** - udział poszczególnych pasów w oddychaniu, reprezentowany przez 5 wartości, po jednej dla każdego pasa. Jest on wyznaczany poprzez zsumowanie wartości głębokości oddechu dla każdego pasa, tworzy to mianownik ułamka, który liczony jest osobno dla każdego tensometru, gdzie licznikiem jest głębokość oddechu dla tego konkretnego sensora
- **belt_share_std** - wyznaczany jest on analogicznie do powyższego, korzysta jednak z wyżej wspomnianych odchyżeń standardowych sygnału, jako głębokości
- **breathing_phase_lengths** - jest to wartość średnia czasu trwania kolejnych faz oddychania, a mianowicie: faza wdechu, pauza po wdechu, faza wydechu, pauza po wydechu

Ostateczna postać wektora cech:

```
{
  "bpm": 9.000900090009,
  "breath_depth": 0.000508883499999989,
  "breath_depth_std": 0.000536447969322273,
  "belt_share": [
    0.22835596917392076,
    0.23058806904451593,
    0.23666638543899532,
    0.11107859100193478,
    0.19331098534063318
  ],
  "belt_share_std": [
    0.22813856117990958,
    0.19352652793035194,
    0.21559730281491984,
    0.16293926980008244,
```

```

0.19979833827473617
],
"breathing_phase_lengths": [
    2488.3888888888887,
    105.5,
    3351.6111111111113,
    72.61111111111111
],
"person": "JD_sit"
}


```

2.3 Wizualizacja danych


Aby zweryfikować poprawność całego procesu przetwarzania należało w odpowiedni sposób zwizualizować dane pozyskane w ramach projektu. Jest to niezbędny etap, gdyż pozwala na ewaluację postępów.

Trzy główne cele etapu to:

1. **Weryfikacja rozróżnialności osób po przetwarzaniu** - Aby móc zweryfikować poprawność procesu przetwarzania, trzeba zwizualizować zebrane dane. Jest to realizowane za pomocą algorytmów redukujących liczbę cech: **MDS** oraz **PCA**. W tym podpunkcie liczba składowych, w celach poglądowych, obniżana jest do dwóch. Dzięki tym wartościom jesteśmy w stanie wyznaczyć kierunek, będący transformacją macierzy danych, który spowoduje największe możliwe zróżnicowanie zbioru danych. Zakładając więc, że różnice we wzorcach oddechowych między różnymi osobami będą stosunkowo dużo większe niż między różnymi momentami dla tej samej osoby, jesteśmy w stanie uzyskać odpowiednią, wizualną separację danych, zgodną z etykietami.
2. **Wyznaczenie najbardziej istotnych cech dla klasyfikatora** - W celu wyżej wspomnianej weryfikacji przetwarzania danych, należało zredukować liczbę wymiarów wektora cech, tak by ten mógł zostać przedstawiony w sposób możliwy do analizy przez człowieka. Zostały więc wyznaczone w ten sposób najbardziej istotne elementy sygnału. Dzięki temu jesteśmy w stanie zredukować ostateczną ich liczbę, co pozytywnie wpływa na ryzyko zbytniego dopasowania oraz pozwala na mniejszy nakład obliczeniowy związany np. ze skorelowanymi zmiennymi.



Rysunek 2.5: Cechy po wywołaniu algorytmu MDS przedstawione na dwuwymiarowym wykresie.




Rysunek 2.6: Cechy po wywołaniu algorytmu PCA przedstawione na dwuwymiarowym wykresie.

3. **Kontrola jakości przez prosty klasyfikator** - Ostatnim celem Wizualizacji jest kontrola jakości rozwiązania dzięki klasyfikatorowi. Skorzystano więc z prostego klasyfikatora binarnego: **SVM**, który wykorzystywany jest do porównywania zbiorów danych o dwóch różnych etykietach. Przy okazji wizualizacji wyznaczana jest też wartość liczbową dokładności takiego klasyfikatora. Użycie tego konkretnego algorytmu pozwoli na podkreślenie ewentualnych problematycznych par podobnych zbiorów danych.


Opis przeprowadzonej ewaluacji

2.3.1 SVM - Support Vector Machine


Za pomocą klasyfikatora SVM, jesteśmy w stanie podzielić zbiór na dwa, poprzez znalezienie odpowiedniej hiperpłaszczyzny maksymalizującej margines między dwoma klasami. W związku z tym, że jest on klasyfikatorem binarnym, należało wywołać go osobno dla każdej możliwej pary etykiet w ogólnym zbiorze zredukowanych cech. W ten sposób uzyskujemy podział dla wszystkich kombinacji oraz związaną z nimi dokładność. Poniżej przykłady dla zbioru danych 3 osób.



Zmierzona dokładność: Accuracy for JD_sit and MJ_sit: 95.56%



Zmierzona dokładność: Accuracy for JD_sit and MK_sit: 84.93%



Zmierzona dokładność: Accuracy for MJ_sit and MK_sit: 91.07%


2.4 Tworzenie profili oddechowych osób

Ostatnim etapem analizy danych jest wytworzenie unikatowego i uśrednionego profilu oddechowego dla każdej osoby objętej badaniem na podstawie szeregu wyznaczonych cech. Proces ten pozwala na wyznaczenie wzorca charakterystycznego oddechu dla konkretnego użytkownika, co może służyć jako punkt odniesienia w dalszych badaniach nad biometryczną identyfikacją lub diagnostyką. Wytworzony profil zawiera zarówno uśrednione wartości kluczowych cech czasowo-amplitudowych, jak i reprezentatywny sygnał oddechowy - pojedynczy oddech będący dominantą wśród analizowanych danych.

2.4.1 Metodyka wyznaczania profilu


Tworzenie profilu opiera się na następujących operacjach:

- Wyznaczaniu parametrów liczbowych każdego oddechu w zbiorze danych danej osoby.
- Uśrednianiu oraz wyznaczaniu dominanty tych parametrów.
- Selekcji najbardziej reprezentatywnego cyklu oddechowego na podstawie tych danych obarczonych eksperymentalnie ustalonymi wagami.
- Zapisaniu tych parametrów do dalszej analizy oraz wizualizacji.




Rysunek 2.7: Przykładowy cykl oddechowy stanowiący najbardziej reprezentatywną próbkę. Warto zaznaczyć, że przy tworzeniu najbardziej reprezentatywnego oddechu obecnie stosujemy dwa podejścia:

- **Generowanie syntetycznego sygnału:** Na podstawie wyznaczonych parametrów (amplituda, czas trwania, długości faz oddechowych) generowany jest sztuczny sygnał oddechowy przy użyciu funkcji sinusoidalnych i odpowiednich przesunięć fazowych.
- **Wybór rzeczywistego cyklu oddechowego:** Zamiast generować sztuczny, syntetyczny sygnał, algorytm przeszukuje bazę zarejestrowanych i oczyszczonych oddechów danej osoby. Wybierany jest ten cykl, którego parametry (amplituda, czas trwania i długości poszczególnych faz oddechowych) znajdują się najbliżej wyliczonego matematycznie profilu.



Rysunek 2.8: Przykładowa reprezentacja graficzna profilu oddechowego w postaci wygenerowanego syntetycznego sygnału.



Rysunek 2.9: Przykładowa reprezentacja graficzna profilu oddechowego w postaci wybranego rzeczywistego cyklu oddechowego.

2.4.2 Zastosowanie profili

Na chwilę obecną wygenerowany profil oddechowy pełni jedną niezwykle istotną funkcję w projekcie:


- **Weryfikacja jakościowa:** Pozwala na szybkie porównanie wizualne „typowego” oddechu różnych osób, co potwierdza zasadność użycia algorytmów takich jak MDS czy PCA do ich separacji.

3 Kod źródłowy

Struktura kodu źródłowego została zaprojektowana w sposób modularny, co pozwala na separację logiki przetwarzania sygnałów, ekstrakcji cech oraz wizualizacji rezultatów. Całość implementacji podzielono na trzy główne segmenty funkcjonalne.

3.1 Przepływ sterowania w projekcie

Poniżej umieszczona jest wizualizacja przepływu danych przy wywoływaniu poszczególnych skryptów:



3.2 Architektura systemu

Kod realizuje pełny potok przetwarzania danych (pipeline) – od surowych odczytów z sensorów kamizelki, aż po wizualizację wyników klasyfikacji. Główne moduły to:

- **Przetwarzanie wejścia (Input Processing):** Obsługa plików JSONL, czyszczenie danych (anomalie), wygładzanie spline-ami oraz segmentacja na 2-minutowe interwały.
- **Wykrywanie cech (Feature Extraction):** Przekształcenie sygnału czasowego na wektory cech (np. BPM, głębokość oddechu, fazy oddechu).
- **Wizualizacja danych:** Implementacja algorytmów redukcji wymiarowości (PCA, MDS) oraz ewaluacja separowalności klas przy użyciu SVM.
- **Utworzenie połączenia oraz obsługa zapytań do API:** Warstwa interakcji z BRICS API w celu przesyłu oraz odbioru wyników przetwarzania pomiaru
- **Interakcja z archiwami pomiarów:** Warstwa do wydobycia pobranych pomiarów w celu ich dalszego przetwarzania

3.3 Kluczowe funkcje i przepływ danych wewnątrz skryptu main

Przepływ danych opiera się na klasie `ADC_data`, która przechowuje obrabiane dane na różnych etapach przetworzenia, w tym znormalizowane wyniki pomiarów w woltach. Poniżej przedstawiono kluczowe funkcje procesowe:

1. `process_file()` oraz `handle_input_data()`: Odpowiadają za parsowanie surowego formatu JSON (zawierającego dane z akcelerometrów IMU i tensometrów ADC) do ustandaryzowanych obiektów procesowych.

2. `breath_separation()`: Wykorzystuje analizę ekstremów lokalnych do podziału ciągłego sygnału na pojedyncze cykle oddechowe.
3. `outlier_detection()`: Realizuje filtrację statystyczną, usuwając $x\%$ oddechów o najbardziej odbiegających parametrach czasowo-amplitudowych, co minimalizuje wpływ błędów pomiarowych.
4. `split_data_into_segments()`: Normalizuje długość próbek poprzez resampling i dzieli sygnał na fragmenty ułatwiające dalszą analizę statystyczną.

3.4 Kluczowe funkcje i przepływ danych wewnątrz skryptu `extract_features`

Skrypt ten odpowiada za wyznaczenie wektorów cech dla segmentów oczyszczonego sygnału stanowiącego wyjście poprzedniego skryptu. Realizuje on to przez wybranie segmentów, których procent utraconych danych nie przekroczył wartości `ACCEPTABLE_DATA_LOSS` ustawionej bazowo na 0.2

- `basic_feature_extraction()`: Funkcja, w której środku następuje ekstrakcja wektora cech. Jest ona wywoływana pojedynczo, dla każdego segmentu analizowanego przez skrypt (mniej niż 20% utraty danych). Procedury wykonywane w ramach tej funkcji zostały opisane w sekcji 2.2.5.

3.5 Kluczowe funkcje i przepływ danych wewnątrz skryptu `visualize_data`

Skrypt ten odpowiada za wizualizację danych po przetworzeniu i ekstrakcji cech. Kluczowe funkcje i elementy stanowiące część wizualizacji to:

- `NO_OF_FEATURES_AFTER_ALG`: Stała mówiąca o tym, do ilu cech należy zredukować nasze wektory.
- `FeatureData`: Struktura trzymająca dane zarówno przed, jak i po redukcji cech, etykiety dla danych oraz kolory do wizualizacji.
- `feature_loading`: Funkcja zajmująca się wczytaniem wektorów cech z pliku `extracted_features.jsonl` do wyżej wspomnianej struktury.
- `MDS_algorithm`: Funkcja wywołująca algorytm redukcji cech MDS i wyświetlająca jej wynik na ekranie wraz z etykietami danych.
- `PCA_algorithm`: Funkcja wywołująca algorytm redukcji cech PCA i zapisująca wynik w strukturze.
- `SVM_validation`: Funkcja mająca na celu walidację możliwości podziału zbioru binarnie przez hiperpłaszczyznę.
- `ploteatmap`: Funkcja standaryzująca dane do przedziału $[0,1]$ (dla każdej cechy osobno) i wyświetlająca je za pomocą heatmapy.

3.6 Kluczowe funkcje i przepływ danych wewnątrz skryptu `create_data_profiles`

Skrypt ten odpowiada za tworzenie indywidualnych profili oddechowych każdej osobie, dla której zostały zebrane dane. Dzięki temu możliwe jest przedstawienie i dostrzeżenie indywidualnych cech oddechowych każdej osoby i wizualne potwierdzenie zasadności przeprowadzanego badania. Każdy taki profil jest Pythonową mapą i zawiera:

- **signal**: Jest to wycinek surowego sygnału oddechowego danej osoby zawierający jeden oddech, który statystycznie najlepiej reprezentuje jej sposób oddychania ze względu na szereg parametrów stanowiących kolejne pola tej mapy.
- **timestamps**: Odpowiada za przechowywanie znaczników czasowych odpowiadających kolejnym punktom sygnału.
- **inhale, inspiratory_phase, exhale, expiratory_phase**: Cztery pola odpowiadające kolejnym fazom oddechu. Każde z nich zawiera różnicę w timestampach pomiędzy początkiem i końcem danej fazy.
- **length**: Długość całego oddechu w milisekundach.
- **depth**: Głębokość oddechu, czyli różnica pomiędzy maksymalną a minimalną wartością sygnału w danym oddechu.

Do zadań na przyszłość należy rozszerzenie tej mapy o dodatkowe pola zawierające cechy, które dokładniej pozwolą charakteryzować indywidualny sposób oddychania każdej osoby. Poniżej znajdują się najważniejsze funkcje odpowiadające za tworzenie profili oddechowych:

- **create_data_profiles()**: Główna funkcja tworząca profile oddechowe dla każdej osoby na podstawie przetworzonych danych.
- **get_people_list()**: Funkcja zwracająca listę osób na podstawie etykiet danych znajdujących się w folderze `results`.
- **calculate_breath_characteristics()**: Oblicza fazy oddechu (wdech, faza inspiracji, wydech, faza ekspiracji) na podstawie sygnału dla każdego wykrytego oddechu.
- **get_mode_breath()**: Wybiera najczęściej występujący oddech na podstawie cech statystycznych.
- **visualize_profiles()**: Tworzy wykresy przedstawiające profile oddechowe każdej osoby.

3.7 Utworzenie połączenia oraz obsługa zapytań do API - DatabaseHandler

DatabaseHandler to klasa odpowiadająca za utworzenie środowiska oraz obsługę przygotowanych scenariuszy zapytań do BRICS API. Udostępnia one następujące metody:

- **upload_measurement()**: Wykonuje wysłanie pomiaru oraz jego metadanych do API, co w rezultacie powoduje jego zapis w bazie danych.
- **download_measurement()**: Daje możliwość pobrania pomiarów odpowiadających parametrom wyszukiwania.
- **download_measurement()**: Odpowiada za przesłanie żądania usunięcia pomiaru o danym identyfikatorze.

3.8 Interakcja z archiwami pomiarów

MeasurementDatasetHook to klasa odpowiadająca za automatyczne wydobycie oraz udostępnienie pomiarów znajdujących się w pobranych archiwum ZIP. Dzięki implementacji wewnętrznego iteratora, możliwe jest następujące użycie klasy:

```
mdh = MeasurementDatasetHook(target: raw)

for file in mdh:
    # procesowanie pliku z surowymi danymi
```

4 Serwer BRICS

W celu usprawnionego przechowywania informacji zebranych w trakcie realizacji projektu grupowego utworzono serwer BRICS, udostępniony dla członków zespołu. Rozdział ten ma na celu omówić zaimplementowane zabezpieczenia oraz usługi realizowane przez serwer. Obecnie Serwer BRICS jest realizowany w postaci maszyny używającej narzędzia Docker w celu uruchomienia 5 rodzajów kontenerów:

- **BRICS DB** - bazę danych MongoDB
- **BRICS API** - REST API stanowiące interfejs do BRICS DB
- **Redis** - baza danych stanowiąca pośrednika dla kolejki zadań
- **Celery Worker** - kontener z procesem realizującym zadania z kolejki
- **Celery Beat** - kontener odpowiadający za regularne dodawanie zadań do kolejki

Kolejne sekcje będą miały na celu szczegółowe omówienie realizacji poszczególnych usług powyżej.

4.1 BRICS DB

W celu przechowywania danych użyto systemu MongoDB. Jest to nierelacyjna baza danych, przechowująca informacje w postaci kolekcji zawierających dokumenty.

Baza danych zawiera obecnie jedną kolekcję (poza domyślnymi utworzonymi przez MongoDB):

- **measurements** - dokumenty zawierające informacje na temat pomiarów przechowywanych w systemie plików serwera

Struktura obiektu **MeasurementMetadata**

Pole	Typ	Opis
measurement_id	str	identyfikator pomiaru
timestamp	float	timestamp odpowiadający dacie rozpoczęcia pomiaru
duration_ms	int	długość pomiaru w milisekundach
filepath_raw	str	ścieżka do pliku zawierającego surowe dane pomiarowe
filepath_clean	str	ścieżka do pliku zawierającego oczyszczone dane
filepath_features	str	ścieżka do pliku zawierającego cechy
labels	LabelsData	Obiekt przechowujący dane dot. etykiet i osoby badanej

Struktura obiektu **LabelsData**

activity	str	typ aktywności spośród wybranych
person_data	BioData	Obiekt przechowujący dane dot. osoby badanej

Struktura obiektu **BioData**

person_id	str	identyfikator osoby badanej
age	int	wiek osoby badanej
gender	str	biologiczna płeć osoby badanej
health	str	opis stanu zdrowia
condition	str	kondycja fizyczna osoby badanej spośród wybranych
weight	int	waga osoby badanej w kilogramach
height	int	wzrost osoby badanej w centymetrach

```

_id: ObjectId('69dfa0449406c7beccacabe8'),
duration_ms: 1029207,
filepath_clean: '/dataset/69dfa0449406c7beccacabe8_clean',
filepath_features: '/dataset/69dfa0449406c7beccacabe8_features',
filepath_raw: '/dataset/69dfa0449406c7beccacabe8_raw',
labels: {
  activity: 'sit',
  person_data: {
    person_id: 's198291@student.pg.edu.pl',
    age: 22,
    gender: 'male',
    health: 'healthy',
    condition: 'regular',
    weight: 69,
    height: 172
  }
},
timestamp: 1776263170.8026357

```

Rysunek 4.1: Przykładowy rekord metadanych pomiaru

- **models** - wersje modelu używane w systemie BRICS

4.2 API

W celu komunikacji z wyżej wymienioną bazą danych zostało stworzone REST API, mające na celu ograniczenie dostępu oraz utworzenie warstwy abstrakcji do interakcji z bazą danych. API zostało zrealizowane z użyciem framework'a FastAPI oraz implementacji serwera WWW w technologii Uvicorn.

4.2.1 Punkty końcowe API

By skorzystać z API udostępnione zostały endpoint'y:

- **GET /measurements/download** - służący do pobierania pomiarów odpowiadających parametrom wyszukiwania
- **PUT /measurements/upload** - służący do umieszczania oraz edycji wykonanych pomiarów
- **DELETE /measurements/delete** - służący do usuwania pomiarów

Dostęp do nich jest realizowany w ramach programu poprzez aplikację stanowiącą warstwę interakcji z kamizelką oraz skrypty dostępu, stanowiące realizację warstwy użytkownika tworzącego zbiór danych, pozwalające na wybranie pliku oraz dodanie odpowiednich metadanych, bądź podanie parametrów wyszukiwania.

4.2.2 Szczegółowa realizacja punktów końcowych

Sekcja ta ma na celu dać wgląd w działanie każdego z punktów końcowych.

GET /measurements/download

W żądaniu HTTP do tego punktu końcowego przekazywany jest ciąg znaków będący kwerendą zawierającą filtry wyszukiwania pomiaru. Przetwarzanie tego zapytania można sprowadzić do następujących faz:

1. Utworzenie poprawnej kwerendy do MongoDB na podstawie parametrów żądania
2. Wyszukiwanie metadanych na podstawie kwerendy

3. Wydobycie plików pomiarowych i stworzenie archiwum zip zawierającego pomiary odpowiadające parametrom wyszukiwania
4. Wysłanie odpowiedzi na żądanie
5. Usunięcie folderów tymczasowych utworzonych w ramach przetwarzania żądania

PUT /measurements/upload

W żądaniu HTTP do tego punktu końcowego są przekazywane archiwum zip zawierające trzy pliki będące trzema wersjami oryginalnego pliku pomiarowego oraz ciąg znaków w formacie JSON zawierające metadane tego pomiaru. Przetwarzanie tego zapytania składa się z następujących faz:

1. Weryfikacja poprawności formatu metadanych
2. Wyznaczenie, czy następuje aktualizacja pomiaru czy utworzenie nowego - poprzez wyszukiwanie dostarczonego identyfikatora pomiaru w bazie danych
3. Stworzenie struktur potrzebnych do przekazania procesu finalizacji zapisu pomiaru do kolejki zadań
4. Utworzenie zadania finalizacji zapisu pomiaru do bazy danych oraz systemu plików
5. Odesłanie odpowiedzi o przyjęciu lub odrzuceniu pliku do przetwarzania

Zadanie finalizacji zapisu zostało omówione w sekcji zadań.

DELETE /measurements/delete

W żądaniu HTTP do tego punktu końcowego przekazywany jest jedynie identyfikator pomiaru do usunięcia z bazy danych. Przetwarzanie składa się z następujących faz:

1. Wyszukiwanie metadanych zawierających podany identyfikator
2. Usunięcie metadanych oraz plików pomiarowych w przypadku znalezienia dokumentu

4.2.3 Redis

W celu zaimplementowania kolejki zadań użyto bazy danych Redis, znajdującej się całkowicie w pamięci RAM komputera. Ze względu na istnienie do 16 oddzielnych baz danych w ramach jednej instancji Redis (ponumerowanych od 0 do 15), jako kolejki zadań użyto bazy danych nr 0, a jako rejestru stanów wykonywanych oraz wykonanych zadań użyto bazy danych nr 1.

Należy zaznaczyć, że wybór ten jest czysto arbitralny. Zdecydowano się na przechowywanie stanu zadań wykonanych ze względu na rozszerzalność projektu w przyszłości (np. poprzez usługę typu dashboard, w której to zespół tworzący zbiór danych mógłby łatwo sprawdzać stan systemu).

4.2.4 Celery Worker

Technologia Celery pozwala w ramach projektu na utworzenie kontenerów realizujących kolejkę zadań z bazy danych Redis. Pracownik taki przyjmuje zadanie z kolejki, po czym je wykonuje, a jego rezultat zwraca z powrotem do bazy danych. Dzięki zastosowaniu tej technologii wyznaczono następujące zadania:

- Finalizacja procesu przesłania lub aktualizacji pomiaru/modelu
- Codzienny automatyczny zrzut bazy danych oraz plików pomiarów do kopii zapasowej

Finalizacja procesu przesłania lub aktualizacji pomiaru/modelu

Proces ten można rozbić na następujące podzadania:

1. Weryfikacja przekazanych metadanych oraz plików pomiarowych
2. Ekstrakcja i konwersja formatu plików pomiarowych/modelu
3. Atomiczna insercja/aktualizacja plików pomiarowych/modelu w systemie plików
4. Atomiczna insercja/aktualizacja rekordu metadanych w bazie danych

Dzięki realizacji części tego procesu w postaci zadania w kolejce czas wysyłania pomiaru jest znacznie skrócony, co jest głównym sposobem interakcji z Serwerem BRICS.

Codzienny automatyczny zrzut bazy danych oraz plików pomiarów do kopii zapasowej

Proces ten można rozbić na następujące podzadania:

1. Utworzenie kopii zapasowej bazy danych MongoDB
2. Utworzenie kopii zapasowej plików pomiarowych oraz modeli


Dzięki realizacji części tego procesu w postaci zadania w kolejce czas wysyłania pomiaru jest znacznie skrócony, co jest głównym sposobem interakcji z Serwerem BRICS.

4.2.5 Celery Beat

W ramach technologii Celery istnieje również rozwiązanie Celery Beat, pozwalające na regularne dodawanie zadań do kolejki wedle określonych zasad. W ten sposób zrealizowane jest codzienne wykonywanie kopii zapasowych plików na serwerze.

4.3 Zabezpieczenia

Sekcja ta ma na celu wyszczegółowienie rozwiązań zastosowanych w celu realizacji bezpiecznego dostępu członków projektu do serwera BRICS oraz usług przez niego realizowanych. Ich implementację można przedstawić w postaci poniższego diagramu.



Rysunek 4.2: Uproszczony diagram transmisji danych wewnątrz projektu (pomijając kamizelkę BRV)

4.3.1 Konsola zdalna

Serwer BRICS udostępnia członkom zespołu usługę konsoli zdalnej poprzez SSH. Dla każdego z nich utworzono parę kluczy, i jedynym możliwym sposobem dostępu do konsoli jest uwierzytelnienie poprzez takową parę kluczy, efektywnie tworząc whitelistę, zawierającą jedynie określonych członków zespołu. Usługa SSH dostępna jest jedynie z sieci lokalnej serwera, tym samym ustanawiając tunel Cloudflare jako jedyne zdalne medium połączenia.

Przykładowy sposób ustanowienia konsoli zdalnej na serwerze BRICS z maszyny członka zespołu, dla użytkownika brics (główny użytkownik):

```
sudo cloudflared access ssh --hostname brics-ssh.electimore.xyz --url localhost:5555  
ssh brics@localhost -p 5555
```

4.3.2 API

Dostęp do API możliwy jest jedynie poprzez okazanie odpowiedniej wartości (Service Token) w nagłówkach żądań HTTP. Wartość ta jest zmienną środowiskową, przekazaną każdemu z członków zespołu. Żądania jej niezawierające zostaną odrzucone już na poziomie Cloudflare'a.

4.3.3 Docker

Do reszty usług bezpośredni dostęp jest niemożliwy ze względu na ustawienia zapory sieciowej serwera. Należy się wpierw połączyć poprzez konsolę zdalną, by móc działać bezpośrednio z resztą skonteneryzowanych usług.

5 Płytką pośrednicząca w komunikacji

Aby usprawnić pobieranie danych przy pomocy kamizelki BRV utworzona została płytką pośrednia, która ma za zadanie odbierać dane przekazywane szeregowo i wysyłać je dalej przy pomocy technologii Bluetooth. W tym rozdziale omówiona zostanie budowa płytki, oraz struktura zaimplementowanego oprogramowania. W tym momencie płytką pośrednia udostępnia następujące usługi:

- **BRICS BLE** - serwer Bluetooth LE w trybie Peripheral
- **BRICS Serial** - wielowątkowa aplikacja pobierająca szeregowo dane z kamizelki BRV
- **BRICS.service**

Usługi te są dostępne razem z podłączoną kamizelką BRV i mają na celu jedynie usprawnienie przekazywania danych i ograniczenie utraty danych podczas pomiarów.

5.1 Architektura płytki

Płytką została zrealizowana przy pomocy mikroprocesora Raspberry Pi Zero W, na którym zainstalowany został system operacyjny Raspbian 32-bit. Posiada 64 GB pamięć w postaci karty micro SD.

Schemat połączeń:

5.2 Wielowątkowa aplikacja pośrednicząca

Do obsługi współbieżnego przetwarzania danych zaimplementowana została wielowątkowa aplikacja. Uruchomienie aplikacji powoduje uruchomienie dwóch wątków:

- **BRVBluetoothServer** - wątek obsługujący działanie serwera Bluetooth, którego specyfikacja zostanie omówiona w dalszej części dokumentu.
- **BRVSerialConnection** - wątek obsługujący szeregowe pobieranie pakietów danych z kamizelki BRV.

Komunikacja pomiędzy wątkami została zrealizowana przy pomocy bibliotek:

- **queue** - biblioteka udostępniająca kolejkę FIFO z wbudowanym mechanizmem blokowania
- **asyncio** - biblioteka umożliwiająca asynchroniczne uruchamianie kodu
- **threading** - biblioteka umożliwiająca tworzenie i kontrolowanie wątków

Dane otrzymane na porcie szeregowym są umieszczane w tej kolejce i zdejmowane przez wątek obsługujący serwer Bluetooth. W przypadku, w którym aplikacja napotka błąd lub nieobsłużony wyjątek wątki są niszczone i aplikacja jest uruchamiana ponownie.

5.3 Serwer Bluetooth

W celu utworzenia serwera BLE wykorzystane zostały biblioteki:

- **bluez** - podstawowa biblioteka służąca do tworzenia połączeń wykorzystujących technologię Bluetooth
- **bluez-peripheral** - biblioteka służąca do tworzenia serwerów BLE wykorzystujących bibliotekę Bluez, oraz GATT API
- **dbus** - biblioteka służąca do komunikacji z wykorzystaniem głównej szyny danych

Utworzony serwer składa się z dwóch klas, jedna z nich stanowi deklarację serwisu udostępnianego przez serwer Bluetooth, a druga obsługę wątku uruchamiającego serwer Bluetooth.

Serwer działa w 2 następujących po sobie fazach:

1. **Uruchamianie** - podczas tej fazy serwer musi zadeklarować swoje serwisy, charakterystyki, adapter, agent i rozgłaszanie. Dane o serwisie i charakterystyce dostępnej na płycie definiowane są w klasie **BRVDataService**, a sposób rozgłaszania, agent oraz adapter definiowane są podczas inicjalizacji serwera w klasie **BRVBluetoothServer**. Ponadto, podczas inicjalizacji wątek dostaje od systemu szynę danych d-bus, na której wykonywana będzie konieczna komunikacja ze sterownikami Bluetooth i kolejno inicjalizowane są kolejne elementy serwera.
2. **Działanie** - podczas tej fazy kolejno zdejmowane są kolejne pakiety z kolejki FIFO, oraz rozdzielane na mniejsze aby umożliwić ich transport przy pomocy Bluetooth. Aby wysłać pakiet na dostępnej charakterystyce serwisu uruchamiana jest metoda **update_BRV_value**, która powoduje wygenerowanie powiadomienia. Wszystkie urządzenia, które są podłączone pod system powiadomień tej charakterystyki otrzymują informacje o jej zmianie i mogą odczytać wartość

5.3.1 Działanie serwera Bluetooth LE

Serwer Bluetooth LE (Low Energy) składa się z kilku znaczących komponentów. Głównym z nich jest serwis.


5.4 Sygnalizowanie stanu płytki GPIO

5.5 Przykładowy scenariusz użycia

6 Model BRICS

6.1 Organizacja repozytorium

Nasze repozytorium modelu podzieliśmy na 4 różne składowe zgodnie z poniższym diagramem pakietów UML:



- **Classifiers** - sekcja poświęcona jest klasyfikatorom i ich danym, które funkcjonują jako dodatkowe rozszerzenia naszej aplikacji. Są to głównie skrypty pozwalające na dodatkową wizualizację i przegląd naszych danych poprzez wykonywanie klasyfikacji na różnych stopniach przetwarzania i jakości danych.
- **Data** - jest to głównie przestrzeń przechowywania danych do nauki naszego głównego klasyfikatora oraz dla klasyfikacji wykorzystywanej w aplikacji, działającej na świeżych plikach z kamizelki.
- **Model** - obszar, w którym przechowujemy większość klas i skryptów potrzebnych do wytrenowania i wdrożenia oraz integracji naszego modelu z aplikacją. Przechowywane są tutaj takie pliki jak: wagi modelu, parametry uczenia modelu, skrypty treningowe, czy definicje klas, będących kontenerami na dane.
- **App** - główne miejsce zarządzania pozostałymi elementami repozytorium, w którym integrujemy mechanizmy klasyfikacji, model oraz zarządzanie nim. Jest to zarówno interfejs do posługiwania się repozytorium, jak i nasz końcowy produkt, który mamy na celu rozwijać w projekcie.

6.2 Klasyfikatory

6.3 Dane

6.4 Model

Głównym celem naszego projektu grupowego było stworzenie modelu nauczania maszynowego, którego celem była identyfikacja osób na podstawie wzorców oddechowych. W związku z tym należało zaplanować technologie i sposób przechowywania informacji o modelu, takich jak: wagi, parametry, słownik do etykiet.

W ramach realizacji sieci neuronowej, zdecydowaliśmy się na użycie biblioteki specjalnie przeznaczonej do tego typu zadań czyli **PyTorch**. Posłuży nam ona nie tylko do trenowania modelu, ale także przygotowywania danych i ewaluacji dokładności modelu.

6.4.1 Klasy będące pojemnikami na dane

Klasy kontenerowe mają na celu uporządkowanie struktury danych wraz z ich metadanymi, nie tylko etykietami, lecz również parametrami takimi jak funkcja straty czy liczba wejść i wyjść. Poniżej przedstawiono je w formie tabularyzowanej:

- Struktura obiektu **FeatureData** - jest to kontener przetrzymujące dane w formie dwuwymiarowej tablicy, gdzie każdy rząd jest równoznaczny wektorowi cech z jednego segmentu. Do każdego rzędu przypisana jest również etykieta identyfikująca osobę.

Pole	Typ	Opis
data	NDArray[float64]	dwuwymiarowa tablica z danymi
labels	NDArray[int]	wektor zawierający etykiety danych

- Struktura obiektu **BRICSModelWrapper** - jest to klasa umożliwiająca nam przetrzymanie modelu oraz jego parametrów do trenowania czy użytkowania. Dodatkowo są tu również przechowywane słowniki do etykiet oraz cech, przekształcające identyfikatory na łańcuchy znaków. Klasa posiada również metody, które korzystają z wyżej wymienionych słowników, lub z samego modelu.

Pole	Typ	Opis
parameters	dict	Słownik z parametrami treningowymi
people_keys	dict	Słownik mapujący id osoby na osobę
feature_keys	dict	Słownik mapujący id cechy na cechę
model	BRICSModel	Klasa modelu

Metody zaimplementowane w klasie:

Metoda	Zwracany typ	Opis
get_person(id: int)	str	Zwraca łańcuch znaków będący żadaną osobą
identify_person(input: Path)	str	Zwraca łańcuch znaków będący osobą zidentyfikowaną
save_model()	None	Zapisuje model i uzupełnia parametry
load_model()	None	Wczytuje model i uzupełnia parametry


- Struktura obiektu **ModelData** - jest to kontener przechowujący poprzednie dwie Klasy oraz obiekty DataLoader potrzebne przy przygotowywaniu kolejnych serii danych do epok.

Pole	Typ	Opis
feature_data	FeatureData	Obiekt z danymi cech
model_wrapper	BRICSModelWrapper	Obiekt z parametrami i modelem
train_loader	DataLoader	Obiekt seryjnego ładowania danych
feature_data	FeatureData	Obiekt seryjnego ładowania danych

6.4.2 Model nauczania maszynowego

Architektura sieci neuronowej

Nasza sieć została stworzona w następującej postaci:



Posiada ona 3 warstwy odpowiadające za przetwarzanie danych:

- **input**

Rozmiarem wejścia dla tej warstwy jest liczba cech w pojedynczym wektorze cech. Dodatkowo, wyjście tej warstwy, w postaci 32 wartości wstępnych cech, jest przekazywane do funkcji aktywacji ReLU przed dalszym przetwarzaniem.

- **hidden**

Liczba wejść do neuronów wejściowych w tej warstwie to 32. Liczba ta jest podyktowana głównie optymalizacją przetwarzania równoległego na rdzeniach karty graficznej, które działają optymalnie dla wartości będących potęgą 2. Dodatkowo, wyjście tej warstwy w postaci 64, bardziej wyszczególnionych cech, również przekazywane jest do funkcji aktywacji ReLU przed dalszym przetwarzaniem.

- **output**

Rozmiar wejścia tej warstwy to 64 i jest to ostatnia warstwa naszego modelu, w której dokonujemy klasyfikacji osób, więc wyjściem będzie wektor wartości z poziomem aktywacji dla każdej klasy(osoby), na której trenowany był model. Wartość ta określana jest mianem logita. Nie są to więc bezpośrednio prawdopodobieństwa klas, co oznacza, że jeżeli chcemy takowe uzyskać, należy wywołać na wyjściu funkcję `softmax`, bądź jeżeli interesuje nas tylko najwyższa wartość, funkcję `argmax`.

6.4.3 Założenia treningowe

W celu wytrenowania naszego modelu musieliśmy poczynić pewne założenia i przygotowywania projektu, tak aby należycie uporządkować naszą przestrzeń pracy. Kluczowe było sformalizowanie poniższych

zagadnień:

Sposób przechowywania danych o modelu poza działaniem programu

W celu późniejszego załadowania już wytrenowanego modelu, np. z bazy danych, należało się zastanowić nad formą zapisu parametrów potrzebnych do funkcjonowania. zdecydowaliśmy się więc zapisać 3 poniższe pliki:

- `model.pth` - jest to plik binarny, stworzony przez funkcję zapisu modelu z biblioteki PyTorch. Zawiera on rezultat treningu, czyli zbiór wag neuronów będących rezultatami treningu
- `model.jsonl` - są to parametry zapisane w formacie `jsonl`, które umożliwiają nam załadowanie już istniejącego modelu, ponieważ trzymają one informacje zawarte w polach klas okalających model. Zawartość przykładowego pliku prezentuje się następująco:

```
{
  "parameters": {
    "optimizer": "Adam",
    "criterion": "CrossEntropyLoss",
    "learning_rate": 0.001
  },
  "people_keys": {
    "0": "person1@poczta.pl",
    "1": "person2@gmail.com",
    "2": "person2@onet.pl",
    "3": "person2@mymail.com",
  },
  "feature_keys": {
    "0": "bpm",
    "1": "avg_breath_depth",
    "2": "avg_breath_depth_std_dev",
    "3": "phases_avg_values1",
    "4": "phases_avg_values2",
    "5": "phases_avg_values3",
    "6": "phases_avg_values4",
    "7": "breath_shape1",
    "8": "breath_shape2",
    "9": "breath_shape3",
    "10": "breath_shape4",
    "11": "breath_length_variability",
    "12": "breath_amplitude_variability",
    "13": "belt_share1",
    "14": "belt_share2",
    "15": "belt_share3",
    "16": "belt_share4",
    "17": "belt_share5",
    "18": "belt_share_std1",
    "19": "belt_share_std2",
    "20": "belt_share_std3",
    "21": "belt_share_std4",
    "22": "belt_share_std5"
  }
}
```


- **scaler.pkl** - jest to plik przechowujący parametry użyte podczas skalowania danych do treningu. Jest on wymagany w celach późniejszego wczytania go jako obiektu klasy **StandardScaler** odpowiedzialnej za skalowanie danych już w środowisku produkcyjnym, ponieważ tam nie posiadamy danych, na których trenowany był model.

Sposób definiowania hiperparametrów do treningu

W tym celu zdecydowaliśmy się stworzyć osobny plik nazwany **hyperparameters.py**, który zawiera stałe do trenowania takie jak:

- **EPOCHS** - liczba iteracji treningu modelu.
- **BATCH_SIZE** - liczba punktów danych (wektorów cech) ładowanych za jednym przejściem przed wywołaniem propagacji wstecznej.
- **LEARNING_RATE** - stała szybkości uczenia.
- **DROPOUT** - stosunek losowych próbek, które należy odrzucić podczas trenowania w celu dywersyfikacji danych.

Sposób podziału danych treningowych i testowych

Ponieważ nie posiadamy jeszcze bardzo dużej ilości danych, nie zdecydowaliśmy się na zawarcie w naszym procesie uczenia modelu zbioru danych walidacyjnych. W związku z tym zdecydowaliśmy się na najbardziej podstawowy stosunek podziału danych treningowych i testowych **80% danych treningowych, 20% danych testowych**

Ustalenie przepływu danych i przebiegu treningu


Nasze dane zdecydowaliśmy się umieścić w klasie **DataLoader** z biblioteki PyTorch, gdyż jest to wyjątkowo wygodny sposób ładowania danych w seriach w celu zrównoleglenia przetwarzania.

Dodatkowo, na tym etapie należało również wybrać nasz optymalizator i funkcję straty, którymi będziemy się posługiwać przy treningu. Zostały więc wybrane dwa sprawdzone rozwiązania, należące do biblioteki:

- optymalizator **Adam** - jest to opcja lepsza niż alternatywa **SGD**, ponieważ dla relatywnie małego zbioru danych osiąga podobne wyniki i cechuje się szybszą zbieżnością. Warto jednak wspomnieć, że system został zaprojektowany w taki sposób, by umożliwiał zmianę tego typu parametrów nawet w czasie uczenia, dzięki wcześniej wspomnianemu słownikowi parametrów **model.jsonl**.
- funkcja straty **CrossEntropyLoss** - jest to podstawowa funkcja występująca w zadaniach klasyfikacji wieloklasowej, którą udostępnia biblioteka.

6.4.4 Przebieg treningu

Trening naszego modelu również został zaplanowany poprzez wspólne wytworzenie diagramu przepływu, który prezentuje się następująco:



Na podanym schemacie można zaobserwować dwa główne elementy będące pętlami, kolejno: trenowania i testu z wynikiem w postaci dokładności.

Najważniejsze etapy

To co zostało przedstawione na diagramie, to przepływ danych podczas wywołania skryptu `train_model.py`. w kolejnych etapach realizowane są poszczególne zadania:

1. **scale_data()** - etap opisany został wywołaniem funkcji należącej do skryptu `parse_features.py`, której zadaniem jest przekształcenie załadowanych cech zgodnie z formatem przedstawionym w sekcji data dokumentacji, tak, by model skuteczniej uczył się zależności na danych o podobnym rzędzie wielkości.

Funkcja wywołuje `StandardScaler` z biblioteki PyTorch, który skaluje nasze dane kolumnowo. Oznacza to, że każda kolumna danych, czyli w naszym przypadku wartości danej cechy dla wszystkich pomiarów, jest skalowana zgodnie ze wzorem:

$$\frac{x - \bar{x}}{\sigma}$$

Gdzie:

x to punkt danych

$\bar{x}$ to średnia z kolumny

σ to odchylenie standardowe danych w kolumnie

2. **Fill data loaders** - etap polegający na załadowaniu etykiet, jak i przeskalowanych cech do obiektów `DataLoader` zarówno treningowych jak i testowych. To właśnie tutaj następuje podział zbioru na treningowy i testowy.
3. **Training loop** - etap, w którym przez nasz model przeprowadzamy dane, on zapisuje wynik, liczy funkcję straty i na jej podstawie przeprowadza propagację wsteczną.

4. **Test loop** - etap walidacyjny, gdzie dane z **DataLoader** są analizowane pod kątem poprawności etykiety po przejściu przez model. Wynikiem tej fazy jest dokładność modelu po liczbie epok zdefiniowanej wcześniej. Dodatkowo, tworzona jest również macierz pomyłek dla danych, ale będzie ona przedstawiona szerzej w sekcji aplikacji.
5. **BRICSModelWrapper** - ostatni etap, czyli załadowanie zmian do klasy okalającej model i zapisanie wyników. Po tej fazie występuje również odgórne zapytanie od interfejsu graficznego o zapisanie modelu, jednak nie jest to częścią opisywanego skryptu, a całego przepływu.

6.5 Aplikacja