

Dokumentacja techniczna projektu

**Dokumentacja projektu grupowego
ID-346 - Analiza bio-sygnałów do identyfikacji osób**

Mikołaj Kuźmich 198291, Jakub Dąbrowski 197629, Mikołaj Jaworski 197636

Spis treści

1	Konwencje	3
1.1	Słownik pojęć:	3
1.2	Metoda pomiarowa	4
1.3	Wykorzystane technologie	4
2	Przetwarzanie danych	6
2.1	Obiekt pomiaru	6
2.1.1	Charakterystyka surowych danych	6
2.2	Etapy przetwarzania danych	7
2.2.1	Obsługa danych wejściowych i wstępne przetwarzanie	7
2.2.2	Oddzielanie oddechów	8
2.2.3	Wykrywanie anomalii	8
2.2.4	Podział danych na segmenty i resampling	10
2.2.5	Ekstrakcja cech	11
2.3	Wizualizacja danych	12
2.3.1	SVM - Support Vector Machine	13
2.4	Tworzenie profili oddechowych osób	16
2.4.1	Metodyka wyznaczania profilu	16
2.4.2	Zastosowanie profili	17
3	Kod źródłowy - toolkit	19
3.1	Przepływ sterowania w głównym potoku przetwarzania <code>data_processing_pipeline</code>	19
3.2	Architektura systemu	19
3.3	Kluczowe funkcje i przepływ danych wewnątrz skryptu <code>initial_data_processing</code>	19
3.4	Kluczowe funkcje i przepływ danych wewnątrz skryptu <code>extract_features</code>	20
3.5	Kluczowe funkcje i przepływ danych wewnątrz skryptu <code>visualize_data</code>	20
3.6	Kluczowe funkcje i przepływ danych wewnątrz skryptu <code>create_data_profiles</code>	21
4	Serwer BRICS	22
4.1	Baza danych	22
4.2	API	22
4.3	Zabezpieczenia	23
4.3.1	Konsola zdalna	23
4.3.2	API	23
4.3.3	Baza danych	23

1 Konwencje


1.1 Słownik pojęć:

- **BRV (Breathing Rhythm Vest)** - kamizelka pomiarowa wyposażona w tensometry, akcelerometry i żyroskopy, służąca do pomiaru rytmu oddechowego u człowieka. Główny instrument pomiarowy, wykonany w ramach pracy magisterskiej innej grupy studentów WETI
- **ADC (Analog-to-Digital Converter)** - przetwornik analogowo-cyfrowy, urządzenie elektroniczne służące do konwersji sygnałów analogowych na cyfrowe. Tu jest to część kamizelki BRV, która przetwarza sygnały z tensometrów na dane cyfrowe do dalszej analizy.
- **Pomiar/badanie** - całość pliku z danymi zebranymi podczas jednego badania, trwającego określonej ilości czasu (np. 10 minut).
- **Próbka** - pojedynczy znacznik czasu z przypisanymi wartościami sygnału ADC z czujników kamizelki BRV.
- **Segment** - wyodrębniony fragment pomiaru o określonej długości czasowej (np. 2 minuty), wykorzystywany do analizy i ekstrakcji cech. Zawiera wiele próbek.
- **Cecha** - wyodrębniona wartość liczbową lub wektor wartości liczbowych, będąca numeryczną reprezentacją pewnego aspektu sygnału oddechowego w danym segmencie.

1.2 Metoda pomiarowa

Dla kamizelki BRV wyznaczono następujący sposób dostosowania poziomu pasów:

- pas 1 - pod pachami
- pas 2 - na linii sutków
- pas 3 - na poziomie najniższego z żeber
- pas 4 - na poziomie pępka
- pas 5 - na poziomie pasa



Rysunek 1.1: Graficzna reprezentacja sposobu noszenia kamizelki pomiarowej BRV.

Obecnie wszystkie wykonane pomiary odbywały się w pozycji siedzącej i w stanie spoczynku. Dopuszczalne były jedynie niewielkie ruchy ciała, takie jak poprawienie pozycji siedzącej czy zmiana ułożenia rąk. Dodatkowo dopuszczaliśmy następujące czynności:

- picie wody,
- używanie telefonu komórkowego
- czytanie książki
- korzystanie z komputera - tu należy zaznaczyć, że było to korzystanie bez znaczących ruchów ciała i w sposób niewzbudzający silnych emocji (może to powodować zmiany naturalnego rytmu oddechowego).

Całe badanie zazwyczaj trwało około 15 minut, ale wykonaliśmy też kilka dłuższych pomiarów. Najdłuższy wykonany pomiar trwał 60 minut. Całkowicie udało się zebrać około 5 godzin materiału pomiarowego od 3 różnych osób. Powiększenie tego zbioru (zarówno pod względem czasu pomiarowego, jak i liczby osób) jest priorytetem na przyszłość.

1.3 Wykorzystane technologie

W projekcie zostały wykorzystane następujące technologie:

- Język programowania Python w wersji 3.12
- Oprogramowanie LaTeX do tworzenia dokumentacji technicznej

- Biblioteka NumPy do obliczeń numerycznych
- Biblioteka SciPy do analizy sygnałów
- Biblioteka Matplotlib do wizualizacji danych
- Biblioteka Seaborn do wizualizacji danych
- Biblioteka SciKit-learn do uczenia maszynowego
- Biblioteka Pathlib do operacji na ścieżkach plików
- Baza danych MongoDB do przechowywania danych pomiarowych
- Framework FastAPI do stworzenia REST API dla bazy danych
- Serwer WWW Uvicorn
- Zbiór narzędzi do wytwarzania i uruchamiania aplikacji skonteneryzowanych Docker

2 Przetwarzanie danych

2.1 Obiekt pomiaru

Obiektem pomiaru jest sygnał oddechowy rejestrowany przez system kamizelki sensorycznej. Pomiar opiera się na analizie zmian obwodu klatki piersiowej i brzucha użytkownika podczas cyklu oddechowego.

System wykorzystuje dwa główne typy sensorów:

- **Tensometry (ADC):** Pięć pasów tensometrycznych rozmieszczonych na różnych wysokościach tułowia. Rejestrują one siłę naciągu pasów, która zmienia się wraz z nabieraniem i wypuszczaniem powietrza.
- **Jednostki inercyjne (IMU):** Zestaw akcelerometrów i żyroskopów monitorujących orientację przestrzenną oraz ruchy klatki piersiowej. Na chwilę obecną dane z tych sensorów nie są wykorzystywane.

2.1.1 Charakterystyka surowych danych

Dane przesyłane z urządzenia mają formę strumienia obiektów JSON. Każda próbka zawiera timestamp oraz surowe odczyty binarne z sensorów.

Poniżej przedstawiono strukturę kluczowych pól surowej próbki:

Klucz sygnału	Typ	Opis fizyczny
hrs, min, sec, ms	czas	Czas rejestracji próbki od uruchomienia urządzenia.
adc1...adc5	24-bit	Trzy 8-bitowe rejestry (np. 23_to_16) tworzące naciąg pasa zapisany w formacie U2
imu1...imu5_acc	m/s ²	Składowe przyspieszenia liniowego w osiach X, Y, Z dla 5 punktów kamizelki.
imu1...imu5_gyr	deg/s	Prędkość kątowna (orientacja) klatki piersiowej i pleców.
output_status	bool	Flaga diagnostyczna określająca poprawność pracy danego sensora.

Tabela 2.1: Opis składowych danych surowych.

Poniżej przedstawiono przykładowy format surowej próbki:

```
"hrs": 0, "min": 0, "sec": 13, "ms": 457,  
"adc1_output_23_to_16": 240, "adc1_output_15_to_8": 8,  
"adc1_output_7_to_0": 165, "adc2_output_23_to_16": 255,  
"adc2_output_15_to_8": 36, "adc2_output_7_to_0": 15,  
"adc3_output_23_to_16": 243, "adc3_output_15_to_8": 99,  
"adc3_output_7_to_0": 199, "adc4_output_23_to_16": 253,  
"adc4_output_15_to_8": 161, "adc4_output_7_to_0": 55,  
"adc5_output_23_to_16": 238, "adc5_output_15_to_8": 46,  
"adc5_output_7_to_0": 1, "imu1_output_acc_x": 2384,  
"imu1_output_acc_y": 237, "imu1_output_acc_z": 16526,  
"imu1_output_gyr_x": -12, "imu1_output_gyr_y": -11,
```

```

"imu1_output_gyr_z": 17, "imu2_output_acc_x": 3021,
"imu2_output_acc_y": 888, "imu2_output_acc_z": 16327,
"imu2_output_gyr_x": -1, "imu2_output_gyr_y": -31,
"imu2_output_gyr_z": 17, "imu3front_output_acc_x": 5654,
"imu3front_output_acc_y": 866, "imu3front_output_acc_z": 15351,
"imu3front_output_gyr_x": -2, "imu3front_output_gyr_y": 7,
"imu3front_output_gyr_z": -5, "imu3back_output_acc_x": -831,
"imu3back_output_acc_y": -2094, "imu3back_output_acc_z": 16238,
"imu3back_output_gyr_x": 2, "imu3back_output_gyr_y": 9,
"imu3back_output_gyr_z": -9, "imu4_output_acc_x": 1997,
"imu4_output_acc_y": 655, "imu4_output_acc_z": 15972,
"imu4_output_gyr_x": -5, "imu4_output_gyr_y": -4,
"imu4_output_gyr_z": -2, "imu5_output_acc_x": -768,
"imu5_output_acc_y": 437, "imu5_output_acc_z": 16111,
"imu5_output_gyr_x": -3, "imu5_output_gyr_y": 3,
"imu5_output_gyr_z": 7, "output_status_adc1": true,
"output_status_adc2": true, "output_status_adc3": true,
"output_status_adc4": true, "output_status_adc5": true,
"output_status_imu1": true, "output_status_imu2": true,
"output_status_imu3front": true, "output_status_imu3back": true,
"output_status_imu4": true, "output_status_imu5": true,
"output_status_padding": 0

```

2.2 Etapy przetwarzania danych

2.2.1 Obsługa danych wejściowych i wstępne przetwarzanie

Pierwszym etapem przetwarzania danych jest ich wczytanie oraz odpowiednie sformatowanie. Dane, zgodnie z opisem w punkcie 2.1, są przechowywane w plikach .jsonl. Każda linia reprezentuje pojedynczą próbkę zarejestrowaną przez kamizelkę pomiarową.

Wczytywanie odbywa się sekwencyjnie. Każda linia zawiera surowe dane czasowe (godziny, minuty, sekundy, milisekundy), 24-bitowe wartości z pięciu przetworników ADC (podzielone na trzy 8-bitowe składowe) oraz dane z czujników inercyjnych IMU.

W celu ułatwienia dalszej obróbki, każda z tych linii jest parsowana do wewnętrznej struktury danych. Proces ten obejmuje połączenie trzech 8-bitowych rejestrów każdego z pięciu kanałów ADC w jedną wartość liczbową, która następnie jest przeliczana na napięcie (wolt) zgodnie ze specyfikacją zastosowanych tensometrów.

Struktura danych wynikowych

Po wstępnym przetworzeniu dane są normalizowane i zapisywane w formie uproszczonych obiektów JSON, które stanowią podstawową jednostkę danych w dalszych etapach projektu. Przykładowy format przetworzonego segmentu (np. 2-minutowego) wygląda następująco:

```

{
  "timestamp": 0,
  "adc_outputs": [
    0.0002464437,
    0.0003881085,
    0.0004560553,
    -1.75746999e-05,
    0.0002706136
  ]
}

```

Tu warto dodać, że dla większości obliczeń wykonywanych w dalszych etapach takich jako wyciąganie cech, separacja oddechów czy wykrywanie anomalii pracujemy na sygnale dla środkowego ADC (ADC numer 3), eksperymentalnie ustaliliśmy, że jest on najbardziej miarodajny w kontekście analizy oddechu, a praca z jednym czujnikiem znacznie upraszcza cały proces.

2.2.2 Oddzielanie oddechów

Celem tego etapu jest wstępne podzielenie sygnału na mniejsze części reprezentujące kolejne oddechy w analizowanym pomiarze. Realizowane jest to poprzez wyznaczenie wszystkich maksymów i minimów lokalnych oraz zapisanie ich w programie tak, by przygotować je do dalszej obróbki.

- **Dane wejściowe:**

Zbiór wartości odstawania od średniej wartości sygnału na danym pasie, dla każdego pasa w kamizelce pomiarowej. Każda z tych wartości przypisany ma odpowiedni znacznik czasu od rozpoczęcia pomiaru, w którym pobrano próbkę.

- **Dane wyjściowe:**

Zbiór punktów reprezentujących wszystkie maksyma i minima lokalne sygnału wraz z przypisanymi im wartościami znaczników czasu.

2.2.3 Wykrywanie anomalii

Kolejnym kluczowym etapem jest identyfikacja oraz eliminacja anomalii (ang. *outlier detection*). Sygnał z czujników tensometrycznych w kamizelce jest podatny na zakłócenia wynikające z nagłych ruchów użytkownika, poprawiania kamizelki czy chwilowych błędów transmisji danych. W ten sposób mogą pojawić się oddechy o nietypowych wartościach, które mogą negatywnie wpłynąć na jakość analizy i klasyfikacji.

Proces ich wykrywania i usuwania opiera się na analizie statystycznej zbioru wyznaczonych wcześniej ekstremów (maksimów i minimów) oraz odległości czasowych między nimi.

- **Kryteria wykrywania anomalii:**


- **Amplituda:** Odrzucane są oddechy o wartościach należących do górnych i dolnych kwartyli rozkładu amplitud. Obecnie odrzucamy około jeden procent oddechów z każdej strony rozkładu.
- **Częstotliwość:** Odrzucane są oddechy o zbyt krótkich oraz długich odległościach między wykrytymi wcześniej maksymami. Obecnie odrzucamy około jeden procent oddechów z każdej strony rozkładu.

- **Dane wejściowe:**


Zbiór par (znacznik czasu, wartość) dla zidentyfikowanych maksimów i minimów lokalnych z poprzedniego etapu oraz znormalizowany sygnał oddechowy.

- **Dane wyjściowe:**


Przefiltrowany zbiór punktów (zmodyfikowany sygnał oddechowy), o odpowiednio przesuniętych wartościach znaczników czasu.




Rysunek 2.1: Wykryte anomalie na podstawie amplitudy dla przykładowego sygnału.



Rysunek 2.2: Wykryte anomalie na podstawie Częstotliwości dla przykładowego sygnału.



Rysunek 2.3: Wykryte anomalie po usunięciu artefaktów dla przykładowego sygnału.



Rysunek 2.4: Odtworzony sygnał po usunięciu anomalii dla przykładowego sygnału.

2.2.4 Podział danych na segmenty i resampling

Ostatnim krokiem przygotowania danych przed ekstrakcją cech jest podział przefiltrowanego sygnału na okna czasowe (segmenty) o stałej długości dwóch minut oraz wykonanie resamplingu.

Najpierw sygnał jest resamplowany do za pomocą interpolacji liniowej (funkcja `interp1d` z biblioteki SciPy) do Częstotliwości 10 Hz, a następnie dzielony na segmenty. Dzięki temu każdy segment zawiera około 1200 próbek. Sam algorytm podziału na segmenty jest raczej prosty - rozpoczynamy od początku sygnału i zapisujemy do kolejnych plików `.jsonl` kolejne próbki danych zawierające się w danym dwuminutowym segmencie.

Tu warto wspomnieć, że segmenty nie muszą być dwuminutowe, a jedynie obecnie, po konsultacjach oraz analizie, zdecydowaliśmy się na takich pracować. Głównym powodem było zachowanie równowagi pomiędzy długością segmentu - tak aby jeden pomiar oferował wiele segmentów do analizy, a ilością danych w pojedynczym segmencie - musi być to miarodajna próbka ludzkiego oddechu, z której da się pozyskać zestaw określonych cech. Dla innych zastosowań projektu np. identyfikacji osoby w czasie rzeczywistym długość segmentów ulegnie zmianie do 10 sekund.

2.2.5 Ekstrakcja cech

Po podzieleniu danych na segmenty, a więc ostatecznym przygotowaniu ich do analizy, należy rozpocząć proces pozyskiwania informacji potrzebnych do prawidłowego działania klasyfikatora. Sama sieć neuronowa nie potrzebuje zdefiniowanych cech sygnału, jednak w celach badawczych, zdecydowano się na ich ekstrakcję ze względu na możliwość sprawdzenia różnic we wzorcach oddechowych objętych analizą osób oraz porównanie efektywności identyfikacji w oparciu o zbiór cech z klasyfikacją sygnałów czasowych (ang. *outlier detection*, TSC).

- **Dane wejściowe:**

Zbiór plików zawierających podzielone na segmenty dane z pomiarów po wszystkich przekształceniach, w których nazwa wyznacza etykietę. Nazwa pliku zawiera typ aktywności oraz identyfikator osoby

- **Dane wyjściowe:**

Plik wyjściowy `extracted_features.jsonl` w formacie `.jsonl`, zawierający wektory cech wyznaczone dla kolejnych segmentów danych pomiarowych.

Cechy składające się na wektor dla segmentu:

- `bpm` - liczba oddechów na minutę
- `avg_breath_depth` - wyznaczone poprzez uśrednienie wartości szczytów oddechów w całym segmencie dla środkowego pasa
- `avg_breath_depth_std_dev` - odchylenie standardowe sygnału, jako głębokość oddechu dla środkowego pasa
- `phase_avg_values1-4` - uśrednione wartości długości poszczególnych faz oddychania
- `breath_shape1-4` - uśrednione wartości współczynników wielomianu aproksymowanego na wszystkich oddechach
- `breath_length_variability` - jest to średnia kwadratowa kolejnych różnic w długości oddechów (RMSSD)
- `breath_amplitude_variability` - jest to współczynnik wariancji obliczony na podstawie wszystkich amplitud oddechów i ich wariancji (CV)
- `belt_share1-5` - udział poszczególnych pasów w oddychaniu, reprezentowany przez 5 wartości, po jednej dla każdego pasa. Jest on wyznaczany poprzez zsumowanie wartości głębokości oddechu dla każdego pasa, tworzy to mianownik ułamka, który liczony jest osobno dla każdego tensometru, gdzie licznikiem jest głębokość oddechu dla tego konkretnego sensora
- `belt_share_std1-5` - wyznaczany jest on analogicznie do powyższego, korzysta jednak z wyżej wspomnianych odchyłeń standardowych sygnału, jako głębokości

Ostateczna postać wektora cech:

```
{
  "bpm": 22.26614295364139,
  "avg_breath_depth": 3.900225777541929e-05,
  "avg_breath_depth_std_dev": 0.00013306949022660511,
  "phases_avg_values1": 940.4347826086956,
  "phases_avg_values2": 0.0,
  "phases_avg_values3": 1178.7826086956522,
  "phases_avg_values4": 103.82608695652173,
  "breath_shape1": 9.196209863545878e-08,
  "breath_shape2": -6.662249686393455e-06,
  "breath_shape3": 9.61982727984441e-05,
  "breath_shape4": -0.00042464473377830305,
  "breath_length_variability": 545.1113966728349,
  "breath_amplitude_variability": 1.1727109719885525,
  "belt_share1": 0.3316531281145216,
  "belt_share2": 0.0650033517833078,
  "belt_share3": 0.1339896910044088,
  "belt_share4": 0.2490435239116464,
  "belt_share5": 0.22031030518611552,
  "belt_share_std1": 0.17940369491358457,
  "belt_share_std2": 0.2232564079584426,
  "belt_share_std3": 0.2208655713802452,
  "belt_share_std4": 0.18995479665889553,
  "belt_share_std5": 0.186519529088832
}
```


2.3 Wizualizacja danych

Aby zweryfikować poprawność całego procesu przetwarzania należało w odpowiedni sposób zwizualizować dane pozyskane w ramach projektu. Jest to niezbędny etap, gdyż pozwala na ewaluację postępów.


Trzy główne cele etapu to:

1. **Weryfikacja rozróżnialności osób po przetwarzaniu** - Aby móc zweryfikować poprawność procesu przetwarzania, trzeba zwizualizować zebrane dane. Jest to realizowane za pomocą algorytmów redukujących liczbę cech: **MDS** oraz **PCA**. W tym podpunkcie liczba składowych, w celach poglądowych, obniżana jest do dwóch. Dzięki tym wartościom jesteśmy w stanie wyznaczyć kierunek, będący transformacją macierzy danych, który spowoduje największe możliwe zróżnicowanie zbioru danych. Zakładając więc, że różnice we wzorcach oddechowych między różnymi osobami będą stosunkowo dużo większe niż między różnymi momentami dla tej samej osoby, jesteśmy w stanie uzyskać odpowiednią, wizualną separację danych, zgodną z etykietami.
2. **Wyznaczenie najbardziej istotnych cech dla klasyfikatora** - W celu wyżej wspomnianej weryfikacji przetwarzania danych, należało zredukować liczbę wymiarów wektora cech, tak by ten mógł zostać przedstawiony w sposób możliwy do analizy przez człowieka. Zostały więc wyznaczone w ten sposób najbardziej istotne elementy sygnału. Dzięki temu jesteśmy w stanie zredukować ostateczną ich liczbę, co pozytywnie wpływa na ryzyko zbytniego dopasowania oraz pozwala na mniejszy nakład obliczeniowy związany np. ze skorelowanymi zmiennymi.

Warto dodać, że przedstawione tutaj cechy, oznaczone jako **"Feature1"** i **"Feature2"** są kombinacjami liniowymi wszystkich poprzednich cech zgodnie z działaniem obu algorytmów redukcji wymiarowości. Nie są one więc możliwe do bardziej szczegółowego opisu. Dodatkowo, nie wszystkie wektory cech zostały na wykresach przedstawione, gdyż dane zostały obcięte powyżej progu trzech odchyłeń standardowych, aby zmaksymalizować czytelność.



Rysunek 2.5: Cechy po wywołaniu algorytmu MDS przedstawione na dwuwymiarowym wykresie.



Rysunek 2.6: Cechy po wywołaniu algorytmu PCA przedstawione na dwuwymiarowym wykresie.

3. **Kontrola jakości przez prosty klasyfikator** - Ostatnim celem Wizualizacji jest kontrola jakości rozwiązania dzięki klasyfikatorowi. Skorzystano więc z prostego klasyfikatora binarnego: **SVM**, który wykorzystywany jest do porównywania zbiorów danych o dwóch różnych etykietach. Przy okazji wizualizacji wyznaczana jest też wartość liczbową dokładności takiego klasyfikatora. Użycie tego konkretnego algorytmu pozwoli na podkreślenie ewentualnych problematycznych par podobnych zbiorów danych.


Opis przeprowadzonej ewaluacji

2.3.1 SVM - Support Vector Machine

Za pomocą klasyfikatora SVM, jesteśmy w stanie podzielić zbiór na dwa, poprzez znalezienie odpowiedniej hiperpłaszczyzny maksymalizującej margines między dwoma klasami. W związku z tym, że


jest on klasyfikatorem binarnym, należało wywołać go osobno dla każdej możliwej pary etykiet w ogólnym zbiorze zredukowanych cech. W ten sposób uzyskujemy podział dla wszystkich kombinacji oraz związaną z nimi dokładność. Poniżej przykłady dla podzbioru 3 osób.

s197629@student.pg.edu.pl and s197636@student.pg.edu.pl divided by linear SVM




Zmierzona dokładność: Accuracy for s197629 and s197636: 100.00%

s197629@student.pg.edu.pl and s198291@student.pg.edu.pl divided by linear SVM



Zmierzona dokładność: Accuracy for s197629 and s198291: 96.55%

s197636@student.pg.edu.pl and s198291@student.pg.edu.pl divided by linear SVM



Zmierzona dokładność: Accuracy for s197636 and s198291: 100.00%


2.4 Tworzenie profili oddechowych osób

Ostatnim etapem analizy danych jest wytworzenie unikatowego i uśrednionego profilu oddechowego dla każdej osoby objętej badaniem na podstawie szeregu wyznaczonych cech. Proces ten pozwala na wyznaczenie wzorca charakterystycznego oddechu dla konkretnego użytkownika, co może służyć jako punkt odniesienia w dalszych badaniach nad biometryczną identyfikacją lub diagnostyką. Wytworzony profil zawiera zarówno uśrednione wartości kluczowych cech czasowo-amplitudowych, jak i reprezentatywny sygnał oddechowy - zestaw 10 oddechów będących dominantą wśród analizowanych danych.

2.4.1 Metodyka wyznaczania profilu

Tworzenie profilu opiera się na następujących operacjach:


- Wyznaczaniu parametrów liczbowych każdego oddechu w zbiorze danych danej osoby.
- Uśrednianiu oraz wyznaczaniu dominanty tych parametrów.
- Selekcji najbardziej reprezentatywnego cyklu oddechowego na podstawie tych danych obciążonych eksperymentalnie ustalonymi wagami.
- Zapisaniu tych parametrów do dalszej analizy oraz wizualizacji.




Rysunek 2.7: Przykładowy cykl oddechowy stanowiący najbardziej reprezentatywną próbkę.

Warto zaznaczyć, że przy tworzeniu najbardziej reprezentatywnego oddechu obecnie stosujemy dwa podejścia:

- **Generowanie syntetycznego sygnału:** Na podstawie wyznaczonych parametrów (amplituda, czas trwania, długości faz oddechowych) generowany jest sztuczny sygnał oddechowy przy użyciu funkcji sinusoidalnych i odpowiednich przesunięć fazowych.
- **Wybór rzeczywistego cyklu oddechowego:** Zamiast generować sztuczny, syntetyczny sygnał, algorytm przeszukuje bazę zarejestrowanych i oczyszczonych oddechów danej osoby. Wybierany jest ten cykl, którego parametry (amplituda, czas trwania i długości poszczególnych faz oddechowych) znajdują się najbliżej wyliczonego matematycznie profilu.



Rysunek 2.8: Przykładowa reprezentacja graficzna profilu oddechowego w postaci wygenerowanego syntetycznego sygnału.




Rysunek 2.9: Przykładowa reprezentacja graficzna profilu oddechowego w postaci wybranego rzeczywistego cyklu oddechowego.

2.4.2 Zastosowanie profili

Na chwilę obecną wygenerowany profil oddechowy pełni jedną niezwykle istotną funkcję w projekcie:

- **Weryfikacja jakościowa:** Pozwala na szybkie porównanie wizualne „typowego” oddechu różnych osób, co potwierdza zasadność użycia algorytmów takich jak MDS czy PCA do ich separacji.
- **Generowanie segmentów w celu testowania modelu:** Posiadając zbiór najbardziej reprezentatywnych oddechów dla danej osoby można w prosty sposób wygenerować sygnał oddechowy, który powinien stanowić statystycznie poprawną próbkę oddechu danej osoby. Można np. wygenerować segment (zgodnie z zadanymi kryteriami - na chwilę obecną jest to czas trwania) i poddać do klasyfikacji zarówno przy użyciu zestawu wyznaczonych, interpretowalnych cech, jak i *TSC*.




Rysunek 2.10: Przykładowa reprezentacja sygnału oddechowego wygenerowanego w oparciu o powyższy opis.

3 Kod źródłowy - toolkit

Struktura kodu źródłowego została zaprojektowana w sposób modularny, co pozwala na separację logiki przetwarzania sygnałów, ekstrakcji cech oraz wizualizacji rezultatów. Całość implementacji podzielono na trzy główne segmenty funkcjonalne.

3.1 Przepływ sterowania w głównym potoku przetwarzania data_processing_pipeline

Poniżej umieszczona jest wizualizacja przepływu danych przy wywoływaniu skryptu `data_processing_pipeline.py`. Zawiera on wywołania z 3 poniższych skryptów w celu przetworzenia i ekstrakcji cech z naszego sygnału, a na koniec wysyła tak przetworzony pomiar do bazy danych.



3.2 Architektura systemu

Kod realizuje pełny potok przetwarzania danych (pipeline) – od surowych odczytów z sensorów kamizelki, aż po wizualizację wyników klasyfikacji. Główne moduły to:

- **Przetwarzanie wejścia (Initial processing):** Obsługa plików JSONL, parsowanie ich na format odpowiedni do analizy, czyli wartości z 5 pasów na przestrzeni czasu.
- **Przetwarzanie wejścia (Outlier detection):** czyszczenie danych (anomalie), wygładzanie spline-ami oraz segmentacja na 2-minutowe interwały.
- **Wykrywanie cech (Feature extraction):** Przekształcenie sygnału czasowego na wektory cech (np. BPM, głębokość oddechu, fazy oddechu).

Dodatkowo, system uwzględnia również wizualizację danych jako osobny, opcjonalny etap.

- **Wizualizacja danych:** Implementacja algorytmów redukcji wymiarowości (PCA, MDS) oraz ewaluacja separowalności klas przy użyciu SVM.

3.3 Kluczowe funkcje i przepływ danych wewnątrz skryptu initial_data_processing

Przepływ danych opiera się na klasie `ADC_data`, która przechowuje obrabiane dane na różnych etapach przetworzenia, w tym znormalizowane wyniki pomiarów w voltach. Poniżej przedstawiono kluczowe funkcje procesowe:

1. `process_file()` oraz `handle_input_data()`: Odpowiadają za parsowanie surowego formatu JSON (zawierającego dane z akcelerometrów IMU i tensometrów ADC) do ustandaryzowanych obiektów procesowych.
2. `breath_separation()`: Wykorzystuje analizę ekstremów lokalnych do podziału ciągłego sygnału na pojedyncze cykle oddechowe.
3. `outlier_detection()`: Realizuje filtrację statystyczną, usuwając $x\%$ oddechów o najbardziej odbiegających parametrach czasowo-amplitudowych, co minimalizuje wpływ błędów pomiarowych.
4. `split_data_into_segments()`: Normalizuje długość próbek poprzez resampling i dzieli sygnał na fragmenty ułatwiające dalszą analizę statystyczną.

3.4 Kluczowe funkcje i przepływ danych wewnątrz skryptu `extract_features`

Skrypt ten odpowiada za wyznaczenie wektorów cech dla segmentów oczyszczonego sygnału stanowiącego wyjście poprzedniego skryptu. Realizuje on to przez wybranie segmentów, których procent utraconych danych nie przekroczył wartości `ACCEPTABLE_DATA_LOSS` ustawionej bazowo na 0.2

- `basic_feature_extraction()`: Funkcja, w której środku następuje ekstrakcja wektora cech. Jest ona wywoływana pojedynczo, dla każdego segmentu analizowanego przez skrypt (mniej niż 20% utraty danych). Procedury wykonywane w ramach tej funkcji zostały opisane w sekcji 2.2.5.

3.5 Kluczowe funkcje i przepływ danych wewnątrz skryptu `visualize_data`

Skrypt ten odpowiada za wizualizację danych po przetworzeniu i ekstrakcji cech. Kluczowe funkcje i elementy stanowiące część wizualizacji to:

- `NO_OF_FEATURES_AFTER_ALG`: Stała mówiąca o tym, do ilu cech należy zredukować nasze wektory.
- `FeatureData`: Struktura trzymająca dane zarówno przed, jak i po redukcji cech, etykiety dla danych oraz kolory do wizualizacji.
- `feature_loading`: Funkcja zajmująca się wczytaniem wektorów cech z pliku `extracted_features.jsonl` do wyżej wspomnianej struktury.
- `MDS_algorithm`: Funkcja wywołująca algorytm redukcji cech MDS i wyświetlająca jej wynik na ekranie wraz z etykietami danych.
- `PCA_algorithm`: Funkcja wywołująca algorytm redukcji cech PCA i zapisująca wynik w strukturze.
- `SVM_validation`: Funkcja mająca na celu walidację możliwości podziału zbioru binarnie przez hiperpłaszczyznę.
- `plotheatmap`: Funkcja standaryzująca dane do przedziału $[0,1]$ (dla każdej cechy osobno) i wyświetlająca je za pomocą heatmapy.

3.6 Kluczowe funkcje i przepływ danych wewnątrz skryptu

`create_data_profiles`

Skrypt ten odpowiada za tworzenie indywidualnych profili oddechowych każdej osobie, dla której zostały zebrane dane. Dzięki temu możliwe jest przedstawienie i dostrzeżenie indywidualnych cech oddechowych każdej osoby i wizualne potwierdzenie zasadności przeprowadzanego badania. Każdy taki profil jest Pythonową mapą i zawiera:

- **signal**: Jest to wycinek surowego sygnału oddechowego danej osoby zawierający jeden oddech, który statystycznie najlepiej reprezentuje jej sposób oddychania ze względu na szereg parametrów stanowiących kolejne pola tej mapy.
- **timestamps**: Odpowiada za przechowywanie znaczników czasowych odpowiadających kolejnym punktom sygnału.
- **inhale, inspiratory_phase, exhale, expiratory_phase**: Cztery pola odpowiadające kolejnym fazom oddechu. Każde z nich zawiera różnicę w timestampach pomiędzy początkiem i końcem danej fazy.
- **length**: Długość całego oddechu w milisekundach.
- **depth**: Głębokość oddechu, czyli różnica pomiędzy maksymalną a minimalną wartością sygnału w danym oddechu.

Do zadań na przyszłość należy rozszerzenie tej mapy o dodatkowe pola zawierające cechy, które dokładniej pozwolą charakteryzować indywidualny sposób oddychania każdej osoby. Poniżej znajdują się najważniejsze funkcje odpowiadające za tworzenie profili oddechowych:

- **create_data_profiles()**: Główna funkcja tworząca profile oddechowe dla każdej osoby na podstawie przetworzonych danych.
- **get_people_list()**: Funkcja zwracająca listę osób na podstawie etykiet danych znajdujących się w folderze `results`.
- **calculate_breath_characteristics()**: Oblicza fazy oddechu (wdech, faza inspiracji, wydech, faza ekspiracji) na podstawie sygnału dla każdego wykrytego oddechu.
- **get_mode_breath()**: Wybiera najczęściej występujący oddech na podstawie cech statystycznych.
- **visualize_profiles()**: Tworzy wykresy przedstawiające profile oddechowe każdej osoby.

4 Serwer BRICS

W celu usprawnionego przechowywania informacji zebranych w trakcie realizacji projektu grupowego utworzono serwer BRICS, udostępniony dla członków zespołu. Rozdział ten ma na celu omówić zaimplementowane zabezpieczenia oraz usługi realizowane przez serwer. Obecnie Serwer BRICS udostępnia trzy usługi:

- **BRICS DB** - bazę danych MongoDB
- **BRICS API** - REST API stanowiące interfejs do BRICS DB
- **usługa konsoli zdalnej poprzez SSH**

Usługi te dostępne są w Internecie głównie z pomocą tunelu HTTP z użyciem Cloudflare, stworzonego z pomocą osoby trzeciej (znajomego członka zespołu), wykorzystując jego prywatną domenę - `electimore.xyz`. W ten sposób możliwe są mechanizmy rate-limiting'u oraz kontroli dostępu.

4.1 Baza danych

W celu przechowywania danych użyto bazy danych MongoDB. Znajduje się ona na prywatnym komputerze uczestnika projektu pod systemem Ubuntu Linux, działając tam jako demon systemowy. Baza danych zawiera obecnie jedną kolekcję (poza domyślnymi utworzonymi przez MongoDB):

- **measurements** - pomiary w postaci ścieżki w systemie plików oraz dotyczące ich metadane

Pole	Typ	Opis
measurement_id	string	identyfikator pomiaru
person_id	string	identyfikator osoby badanej pozwalający na jej identyfikację
timestamp	float	UNIX timestamp odpowiadający dacie rozpoczęcia pomiaru
duration_ms	int	długość pomiaru w milisekundach
measurement_file_path	string	ścieżka do pliku pomiarowego na serwerze
labels	string[]	JSON zawierający wszystkie etykiety dotyczące pomiaru

4.2 API

W celu komunikacji z wyżej wymienioną bazą danych zostało stworzone REST API, mające na celu ograniczenie dostępu oraz utworzenie warstwy abstrakcji do obsługi przesyłu oraz pobierania pomiarów i innych danych z bazy danych. Zostało ono zrealizowane z pomocą framework'a FastAPI oraz implementacji serwera WWW w technologii Uvicorn. Wszystko to uruchamiane jest z odpowiednio skonfiguowanego kontenera używając Docker'a.


By skorzystać z API udostępnione zostały endpoint'y:

- **GET /measurement/download** - służący do pobierania pomiarów odpowiadających parametrom wyszukiwania
- **POST /measurement/upload** - służący do umieszczania wykonanych pomiarów

Dostęp do nich jest realizowany w ramach programu poprzez skrypty dostępu (w trakcie tworzenia w momencie wypełniania tego fragmentu dokumentacji), stanowiące początkową realizację warstwy użytkownika, pozwalające na wybranie pliku oraz dodanie odpowiednich metadanych, bądź podanie parametrów wyszukiwania.

4.3 Zabezpieczenia

Sekcja ta ma na celu wyszczegółowienie rozwiązań zastosowanych w celu realizacji bezpiecznego dostępu członków projektu do serwera BRICS oraz usług przez niego realizowanych. Ich implementację można przedstawić w postaci poniższego diagramu.



Rysunek 4.1: Uproszczony diagram transmisji danych wewnątrz projektu

4.3.1 Konsola zdalna

Jak zaznaczono powyżej, Serwer BRICS udostępnia członkom zespołu usługę konsoli zdalnej poprzez SSH. Dla każdego z nich utworzono parę kluczy, i jedynym możliwym sposobem dostępu do konsoli jest uwierzytelnienie poprzez takową parę kluczy, efektywnie tworząc whitelistę, zawierającą jedynie określonych członków zespołu. Usługa SSH dostępna jest jedynie z sieci lokalnej serwera, tym samym ustanawiając tunel Cloudflare jako jedyne zdalne medium połączenia.

Przykładowy sposób ustanowienia konsoli zdalnej na serwerze BRICS z maszyny członka zespołu, dla użytkownika brics (główny użytkownik):

```
sudo cloudflared access ssh --hostname brics-ssh.electimore.xyz --url localhost:22  
ssh brics@localhost -p 22
```

4.3.2 API

Dostęp do API możliwy jest jedynie poprzez okazanie odpowiedniej wartości (Service Token) w nagłówkach żądań HTTP. Wartość ta jest zmienną środowiskową, przekazaną każdemu z członków zespołu. Żądania jej niezawierające zostaną odrzucone już na poziomie Cloudflare'a. W celach początkowej realizacji warstwy użytkownika głównym medium użycia API są skrypty dostępu, pozwalające na spreparowanie odpowiednich kwerend i załączenie plików koniecznych dla endpoint'ów.

4.3.3 Baza danych

Niemożliwym jest zdalny dostęp do bazy danych. Należy wpierw połączyć się konsolą zdalną poprzez SSH i z jej poziomu wprowadzać ewentualne zmiany w konfiguracji.